Modelo base entrenado para clasificar el perfil de amenaza tecnológica de los territorios colombianos y orientar la adopción de tecnologías militares

Sector elegido: Seguridad y defensa
Proyecto de Aplicación, Etapa 2 - Laura Alejandra Díaz Sastoque (0000288870) & Juan Diego Saldarriaga Muñoz (0000287391)

1. Recordatorio sintético del problema

Colombia ejecuta en 2026 la mayor inversión de modernización militar de su historia sin un modelo basado en datos que oriente qué tecnología desplegar en cada territorio (Ministerio de Defensa de Colombia, 2025). Este documento corresponde a la Actividad 5 de la Unidad 2 (Etapa 2 del proyecto). En la Etapa 1 (Actividad 4 de la Unidad 1) formulamos la pregunta orientadora:

> ***¿Cómo orientar la adquisición, transferencia de tecnología y fabricación de sistemas de seguridad y defensa de las Fuerzas de Colombia en función del perfil de amenaza tecnológica predominante de los municipios colombianos según las variables de actividad armada histórica, geografía operacional y economías ilícitas, de modo que se optimice la inversión de recursos en búsqueda del bienestar de los colombianos y el desarrollo del país?***

La Etapa 1 dejó tres decisiones que condicionan este avance. Primero, el export gratuito de ACLED solo desagrega a departamento, así que respondemos la pregunta a esa escala mientras accedemos al registro municipal. Segundo, ningún departamento tuvo perfil A (IED) o B (drones) dominante bajo la regla del 50 %, por eso la variable objetivo es binaria: **C** (armas convencionales y emboscadas) frente a **D** (amenaza mixta), y en la sección 2 comprobamos que esto se mantiene aun quitando las protestas. Tercero, 33 filas no bastan para entrenar una red, entonces construimos el panel departamento–año que comprometimos. El modelo base estima, con la información disponible al cierre de un año, la probabilidad del perfil del año siguiente:

$$s^{C}_{d,t} = \text{eventos de subtipos C / eventos totales}, \qquad y_{d,t} = 1[s^{C}_{d,t} \geq 0{,}5], \qquad \hat{p}_{d,t} = f_{\theta}(\mathbf{x}_{d,t-1}) = P(y_{d,t} = 1 \mid \mathbf{x}_{d,t-1})$$

El rezago $t-1 \rightarrow t$ cumple dos funciones. Evita la circularidad de predecir la etiqueta con eventos del mismo año que la definen (las fatalidades de t son consecuencia de los mismos ataques que determinan el perfil C) y reproduce el momento real de la decisión, pues el presupuesto de un año se asigna con lo observado hasta el cierre del anterior. La Tabla 1 muestra cómo se operacionalizó cada variable de la Etapa 1.

Tabla 1: Trazabilidad de variables de la Etapa 1 al modelo base

ID	Variable (Etapa 1)	Operacionalización en el modelo base (medida en t−1)	Fuente	Estado
y	Perfil C vs. D	Regla del 50 % y mapeo de subtipos idénticos a la Etapa 1	ACLED	Implementada
x_1	Frecuencia de eventos	log(1 + eventos anualizados)	ACLED	Implementada
x_2	Fatalidades	log(1 + fatalidades anualizadas) y letalidad x_{2b} = fatalidades/eventos	ACLED	Implementada + derivada
x_3	Grupos armados activos	Requiere los campos de actor del registro por evento	ACLED (licencia)	Pendiente (U3)
x_4	Cultivos ilícitos	log(1 + ha de coca), anual en lugar del promedio 2020-2024	SIMCI–UNODC (datos.gov.co)	Implementada
x_5	Cobertura forestal	% del área con dosel arbóreo ≥ 30 %	Global Forest Watch	Fuente sustituta de IGAC
x_6	Distancia a casco urbano	Distancia del centroide departamental a Bogotá (km)	ACLED (centroides)	Proxy departamental
x_7	IPM	Incidencia de pobreza multidimensional 2018 (%)	DANE (2019)	Implementada

2. Descripción del dataset utilizado

El núcleo del dataset es el export agregado semanal de ACLED para Colombia (Raleigh et al., 2010), actualizado al 15 de agosto de 2026: 17.573 registros semana × departamento × subtipo de evento, 12 columnas y 2,2 MB. Desde 2020 quedan 17.533 registros con 33.275 eventos y 13.591 fatalidades. Frente al corte de la Etapa 1, ACLED revisó retroactivamente su base y los registros difieren −0,28 %, los eventos −0,58 % y las fatalidades −1,51 %, pero la partición departamental de la Etapa 1 (17 D y 16 C) se reproduce exactamente. La coca viene de MinJusticia en Datos Abiertos Colombia (Ministerio de Justicia y del Derecho, 2026) y suma 230.028 ha en 2022 y 252.572 ha en 2023, en línea con los totales redondeados de SIMCI (230.000 y 253.000 ha); la cobertura arbórea viene de Global Forest Watch (Hansen et al., 2013; World Resources Institute, 2025), y ambas quedan en caché junto al notebook. El IPM lo tomamos de DANE (2019).

Al agregar por departamento–año obtenemos 231 celdas (33 × 7 años) y, como 2020 solo aporta predictoras, quedan 198 celdas con etiqueta posible, las ≈198 previstas en la Etapa 1. De ellas, 194 tienen eventos, y exigimos al menos 10 por celda porque con menos el error estándar de s^{C} supera 16 puntos y un solo evento decide el perfil. Quedan 171 filas (82 C y 89 D) de 30 departamentos; Guainía, San Andrés y Vaupés salen por no tener ninguna celda confiable. La Tabla 2 resume la evaluación de calidad.

Tabla 2: Evaluación de calidad del dataset de modelado

Criterio	Evidencia	Criterio	Evidencia
Datos faltantes	0 en las 12 columnas	Duplicados	0 exactos y 0 por llave semana–departamento–subtipo
Continuidad temporal	347 semanas consecutivas, sin saltos	Rangos	eventos ≥ 1 y fatalidades ≥ 0 (máx. 85 y 48)
Registros ajenos	32 en aguas internacionales, excluidos	Taxonomía	cada subtipo pertenece a un solo tipo de evento
Balance de clases	48 % C y 52 % D; la prevalencia de C varía entre 32 % (2021) y 62 % (2025)	Sensibilidad de la etiqueta	reasignar los 2 subtipos ambiguos cambia 1 de 171 etiquetas
Confiabilidad	23 celdas con < 10 eventos excluidas	Persistencia	el 86 % de los departamentos repite perfil de un año a otro

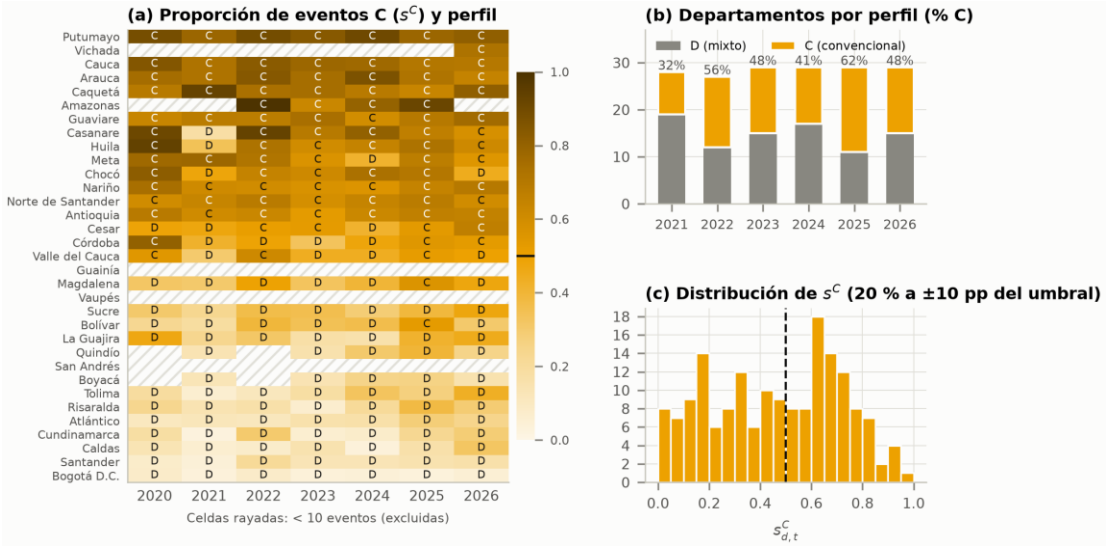


Figura 1: Proporción de eventos C y perfil por departamento–año (a), departamentos por perfil y año (b) y distribución de s^C (c). ACLED Colombia 2020-2026

La Figura 1 muestra los tres rasgos del dataset que condicionan la modelación: la prevalencia de C cambia entre años (mínimo en 2021 por el Paro Nacional y máximo en 2025, año de la crisis del Catatumbo); el perfil es muy persistente, y el 20 % de las celdas tiene s^C a menos de 10 puntos del umbral, donde la etiqueta depende de pocos eventos. Seis de las siete predictoras difieren entre perfiles (Mann-Whitney, $p < 0{,}01$): en mediana, los departamentos C tienen más letalidad (0,52 frente a 0,20), coca (≈5.000 ha frente a 0), bosque (75 % frente a 59 %), distancia (409 frente a 235 km) y pobreza (IPM 30 frente a 17); el volumen de eventos no diferencia ($p = 0{,}06$).

Como pidió la retroalimentación de la Etapa 1, también reconstruimos la etiqueta sin *Peaceful protest* ni *Protest with intervention* (11.009 de 33.275 eventos). Esperábamos que así aparecieran celdas A o B, y no pasó: la celda con más peso de explosivos llega a 21,2 % y la de drones a 13,9 %, lejos del 50 %. Lo que sí cambia es el balance, porque 57 de las 89 celdas D pasan a C y la prevalencia de C sube a 69–96 % según el año, así que la etiqueta binaria casi colapsa en una sola clase. Por eso mantenemos la etiqueta de la Etapa 1, leyendo D como territorio donde la violencia armada directa no alcanza la mitad de los eventos (muchas veces por el peso de la protesta), y dejamos el cambio de regla para la mejora M6.

3. Arquitectura y configuración del modelo base

3.1 Protocolo de entrenamiento y líneas base

La partición respeta el tiempo: **entrenamiento** con etiquetas 2021–2024 (113 filas, 44 % C), **validación** 2025 (29 filas, 62 % C) para la parada temprana y el umbral, y **prueba** 2026 (enero–agosto, 29 filas, 48 % C), que no interviene en ninguna selección. El estandarizador se ajusta solo con entrenamiento. Comparamos el modelo contra tres líneas base: la clase mayoritaria, la **persistencia** ($\hat{p}_{d,t} = s^C_{d,t-1}$, que es lo que haría un planificador sin modelo) y la **regresión logística** con las mismas siete predictoras, es decir, la neurona lineal que la Etapa 1 (§6.3) se comprometió a comparar, con su regularización elegida por el mismo protocolo ($C = 3$).

Antes de entrenar la red revisamos, como pidió el profesor, si la logística da estimaciones estables. Al remuestrear departamentos completos 500 veces, solo dos coeficientes mantienen su signo casi siempre: eventos (−1,78; IC 95 % [−2,39; −0,13]) y fatalidades (+2,55; [0,85; 3,44]). Los otros cinco cruzan el cero, y coca e IPM conservan el signo apenas en el 59–60 % de las réplicas. Es decir, con 29 departamentos de entrenamiento los datos sostienen el contraste

entre volumen y letalidad, pero no el efecto de cada variable estructural por separado; por eso no leemos signos individuales y controlamos la red con parada temprana.

3.2 Arquitectura

El modelo base es un perceptrón multicapa totalmente conectado (API funcional de Keras): 7 entradas estandarizadas, una capa oculta de 16 neuronas ReLU y una salida sigmoide que entrega $\hat{p}$ = P(C), con 145 parámetros entrenables (1,3 por fila de entrenamiento, así que todavía hay más parámetros que datos, la objeción de la Etapa 1). Para datos tabulares un MLP es la arquitectura natural y, con una sola capa oculta, ya es un aproximador universal (Hornik, 1991), el argumento que la Etapa 1 tomó de Bishop y Bishop (2024). Se minimiza la entropía cruzada binaria ponderada por clase más una penalización L2:

$$L(\theta) = -(1/n)\,\Sigma_i\, \omega(y_i)\,[y_i \log \hat{p_i} + (1 - y_i)\log(1 - \hat{p_i})] + \lambda\,\|\mathbf{W}\|^2$$

$$\omega(c) = n\,/\,(2\,n_c)$$

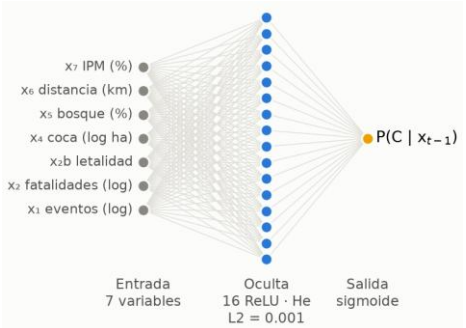


Figura 2: Arquitectura del modelo base (7 → 16 → 1)

Tabla 3: Configuración del modelo base y su justificación

Componente	Elección	Justificación técnica
Capas ocultas	1 capa de 16 neuronas	Elegida por validación cruzada temporal y la regla de 1 error estándar (§3.3); más capas no mostraron ventaja estadística
Activación	ReLU	Derivada 1 en la región activa, sin saturar el gradiente como la logística (máx. 0,25), como se vio en la Actividad 3
Inicialización	He normal, $N(0, 2/n_{in})$	Conserva la varianza de las activaciones en capas ReLU (He et al., 2015)
Salida y pérdida	Sigmoide; BCE ponderada ($\omega_0 = 0{,}90$; $\omega_1 = 1{,}13$)	Log-verosimilitud Bernoulli (Goodfellow et al., 2016); compensa el leve desbalance (44 % C)
Regularización	L2, $\lambda = 10^{-3}$; sin dropout; parada temprana	El dropout empeoró la validación en las 8 comparaciones pareadas; la parada temprana es el regularizador efectivo (Prechelt, 1998)
Optimizador	Adam, $\eta_0 = 10^{-3}$, lotes de 16	Tasa adaptativa por parámetro que tolera gradientes ruidosos (Kingma & Ba, 2015); ≈8 actualizaciones por época
Control	Paciencia de 80 épocas; $\eta/2$ tras 30 épocas sin mejora	Detiene el ajuste en el mínimo de la BCE de validación y restaura esos pesos (máximo 800 épocas)

3.3 Selección de hiperparámetros e implementación

No fijamos la arquitectura a ojo. Comparamos 16 configuraciones (una o dos capas de 8 a 32 neuronas, L2 de 10^{-3} o 10^{-2}, dropout de 0 o 0,2) con validación cruzada temporal de origen móvil, validando en 2023, 2024 y 2025 con los años anteriores (Bergmeir & Benítez, 2012) y dos semillas, para 96 entrenamientos. La mejor BCE media fue la red (32, 16) con 0,285 ± 0,034, pero seis configuraciones quedaron dentro de un error estándar, entonces la regla de 1 EE (Hastie et al., 2009) eligió la más simple: 16 neuronas, L2 = 10^{-3} y sin dropout (BCE de 0,316, con 145 parámetros frente a 801). Todas superaron a la logística (BCE de 0,412). Entrenamos con un bucle explícito con tf.GradientTape compilado en grafo, que registra la norma del gradiente y la razón de actualización por época y fue entre 3,7 y 4,5 veces más rápido que model.fit en los equipos donde lo corrimos; con lote completo, las curvas de pérdida de ambas vías coinciden hasta el orden de 10^{-6}.

4. Métricas de entrenamiento y validación

Tabla 4: Métricas por modelo y conjunto. Fase 2: mismo modelo reentrenado con 2021–2025 y las mismas épocas

Modelo	Conjunto	Exactitud	Exact. balanc.	Sensib. C	Especif. D	MCC	ROC-AUC	Log-loss
Clase mayoritaria	Prueba 2026	0,517	0,500	0,000	1,000	0,000	0,500	0,696
Persistencia	Prueba 2026	0,862	0,867	1,000	0,733	0,755	0,948	0,429
Logística	Entrenamiento	0,832	0,833	0,840	0,825	0,662	0,911	0,376
Logística	Validación 2025	0,793	0,833	0,667	1,000	0,657	0,990	0,433
Logística (fase 1)	Prueba 2026	0,655	0,652	0,571	0,733	0,309	0,762	0,582
Logística (fase 2)	Prueba 2026	0,724	0,724	0,714	0,733	0,448	0,795	0,554
MLP	Entrenamiento	0,823	0,821	0,800	0,841	0,641	0,905	0,410
MLP	Validación 2025	0,759	0,806	0,611	1,000	0,611	0,929	0,473
MLP (fase 1)	Prueba 2026	0,759	0,757	0,714	0,800	0,517	0,795	0,576
MLP (fase 2)	Prueba 2026	0,759	0,757	0,714	0,800	0,517	0,829	0,547

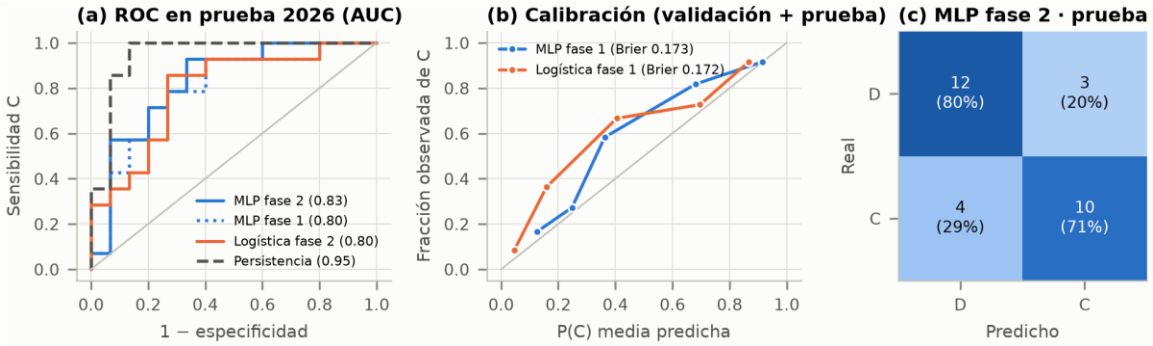


Figura 3: Curvas ROC en la prueba 2026 (a), diagrama de confiabilidad en validación y prueba (b) y matriz de confusión del MLP reajustado (c)

Frente a la clase mayoritaria (AUC 0,50; log-loss 0,70) el MLP aprende una señal real: en la prueba baja la log-loss a 0,55–0,58 y alcanza AUC 0,80–0,83, exactitud balanceada 0,76 y MCC 0,52 (acuerdo moderado corregido por azar), con 10 de 14 departamentos C y 12 de 15 D bien clasificados. Pero se degrada con la distancia temporal: la log-loss sube de 0,41 en entrenamiento a 0,47 en validación y 0,58 en prueba, y reentrenar con 2025 (fase 2) recupera una parte (AUC de 0,795 a 0,829), así que el modelo operativo tendría que reentrenarse cada año. En 2025 el MLP ordena bien (AUC 0,93), pero sus 7 errores son C predichos como D (sensibilidad 0,61), porque la prevalencia de C saltó al 62 % frente al 44 % de entrenamiento; en la Figura 3b ambos modelos quedan por encima de la diagonal, es decir, subestiman P(C) fuera de muestra (Brier 0,173 y 0,172). Por la misma razón el umbral que maximiza F2 en 2025 (0,17) no se transfiere a 2026 (especificidad 0,13) y mantenemos 0,5.

El MLP supera a la logística en la prueba en las dos fases, pero con 29 departamentos los intervalos bootstrap del 95 % se solapan casi por completo (AUC del MLP en fase 2: [0,66; 0,96]), así que la comparación rigurosa la hacemos en §6.3. Y la persistencia gana: repetir el perfil de 2025 acierta 25 de 29 departamentos, porque las variables de la Etapa 1 describen *dónde* hay condiciones para cada perfil, pero no la composición actual del conflicto.

5. Curvas de aprendizaje

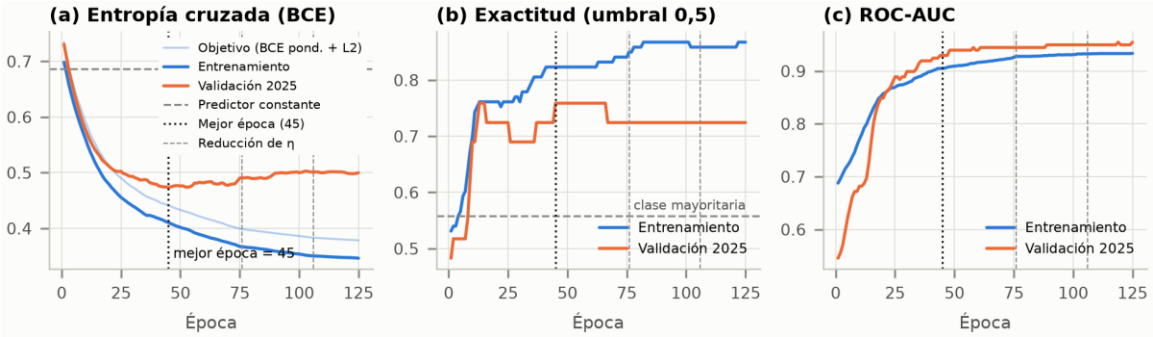


Figura 4: Curvas de aprendizaje del modelo base: BCE (a), exactitud (b) y ROC-AUC (c) por época. Línea punteada: mejor época; líneas discontinuas: reducciones de la tasa de aprendizaje

Ambas pérdidas parten de ≈0,70, el nivel de un predictor constante (0,687), y bajan juntas durante las primeras 20 épocas. La BCE de validación toca su mínimo en la época 45 (0,473, frente a 0,410 en entrenamiento y 6 puntos de brecha en exactitud) y desde ahí sube hasta ≈0,50 mientras la de entrenamiento sigue bajando hasta 0,35: ahí empieza el sobreajuste y la parada temprana restaura los pesos de la época 45. Las dos reducciones de η (épocas 76 y 106) llegan después del óptimo, así que ese mínimo no es un artefacto del optimizador. La AUC de validación (0,93) supera a la de entrenamiento (0,91) aunque la BCE sea peor, otra huella del cambio de prevalencia de 2025, y como cada departamento vale 3,4 puntos de exactitud, el criterio de parada es la BCE, que es continua.

6. Diagnóstico técnico del comportamiento del modelo

6.1 Convergencia y estabilidad

En cuanto a la convergencia, la pérdida desciende de forma monótona: el 90 % de su reducción se logra hacia la época 65 y en las últimas 20 épocas la pendiente es de -2×10^{-4} por época, es decir, una meseta. La norma del gradiente cae de 0,78 a 0,36 y se estabiliza; no llega a cero por el ruido de los minilotes y el equilibrio con el término L2, pero su media móvil deja de bajar. La razón de actualización pasa de $\approx10^{-2}$ a $7–9\times10^{-4}$, dentro de la banda de referencia, sin explosiones ni congelamiento, y responde con un escalón a cada reducción de η. La red converge a un mínimo estable y el óptimo de validación (época 45) llega antes de la meseta de entrenamiento (≈65), así que lo que limita al modelo es la generalización y entrenar más no lo mejoraría.

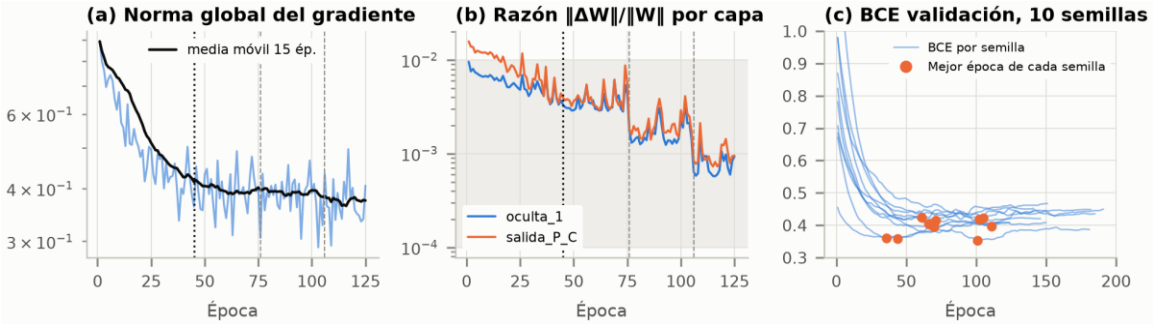


Figura 5: Norma global del gradiente (a), razón de actualización de los pesos por capa con la banda de referencia 10^{-4}–10^{-2} (b) y BCE de validación para 10 semillas con su mejor época (c)

Para medir la estabilidad reentrenamos la red con 10 semillas: el AUC de prueba es 0,848 ± 0,024 (CV 2,8 %) y la BCE 0,493 ± 0,027 (CV 5,4 %), así que el resultado es reproducible. La época óptima sí varía (36 a 111; CV 35 %), porque la BCE de validación forma un valle ancho y plano (Figura 5c). El modelo base (semilla 42) quedó en la cola desfavorable (AUC de 0,795, por debajo del mínimo de las 10 semillas), por eso los reentrenamientos posteriores sin validación usan el presupuesto mediano (70 épocas, 560 pasos); la fase 2 de la Tabla 4 conserva las 45 épocas de la fase 1. Promediar las 10 redes sube el AUC a 0,871, y el 66 % de los departamentos de prueba recibe la misma predicción de todas; los desacuerdos se concentran cerca del umbral.

6.2 Generalización

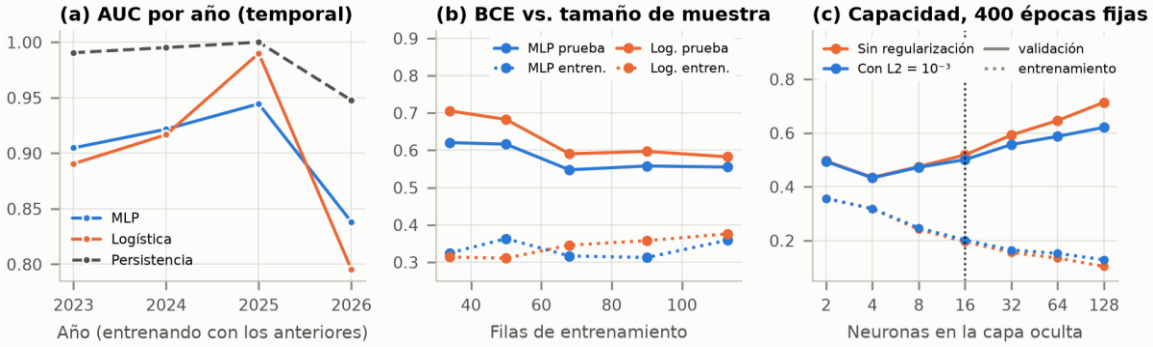


Figura 6: AUC por año en la validación temporal de origen móvil (a), BCE según el tamaño de la muestra de entrenamiento (b) y BCE según la capacidad de la capa oculta con 400 épocas fijas (c)

En el eje temporal, al predecir cada año de 2023 a 2026 con los años anteriores (116 predicciones fuera de muestra), el MLP logra AUC 0,89, exactitud 0,80 y log-loss 0,44, a la par de la logística (0,88; 0,80; 0,45); le gana en 2023, 2024 y 2026 y pierde en 2025, el año del cambio de prevalencia. En el eje espacial el resultado es más débil: dejando fuera un departamento a la vez (30 pliegues; Roberts et al., 2017), el AUC del MLP cae a 0,78 y el de la logística a 0,82. Aquí nos llevamos una sorpresa. Con 5 pliegues de GroupKFold el resultado cambiaba entre nuestro equipo y Colab (AUC del MLP de 0,80 frente a 0,76), porque cada versión de scikit-learn desempata distinto los departamentos con el mismo número de filas. Al repetir la validación con 20 particiones aleatorias de 5 pliegues, el AUC del MLP va de 0,74 a 0,81 y el de la logística de 0,77 a 0,85, pero la logística gana en 17 de las 20; la dirección se sostiene aunque el número exacto dependa de la partición, y por eso reportamos dejar un departamento fuera, que no tiene desempates.

Con 30 departamentos y variables estructurales casi constantes, la red aprovecha su flexibilidad para ajustar firmas departamentales que no se transfieren, y esa es la limitación más importante para clasificar municipios nuevos. En cuanto a sesgo y varianza, la brecha entre entrenamiento y prueba (≈0,2) no se cierra con 113 filas y la mejora se aplana porque sumar años de los mismos departamentos aporta poca información: faltan unidades más que años (Figura 6b). Sin parada temprana, la BCE de validación crece de 0,43 con 4 neuronas a 0,71 con 128 (Figura 6c), así que el regularizador efectivo es la parada temprana.

6.3 ¿Aporta la no linealidad?

En desempeño, la hipótesis de la Etapa 1 no se confirma a esta escala. En la validación temporal, la red y la logística aciertan cada una 5 casos que la otra falla (McNemar exacta, p = 1,0; Dietterich, 1998) y la diferencia de AUC (+0,018) tiene un intervalo bootstrap que incluye el cero [−0,010; 0,045]. En la espacial la logística es significativamente mejor en AUC (ΔAUC −0,039 [−0,073; −0,007]) y en log-loss (ΔBCE +0,075 [0,022; 0,132]), aunque en aciertos McNemar no detecta diferencia (p = 0,80). En la forma, en cambio, la red aprende lo que la Etapa 1 anticipó (Friedman, 2001): fronteras curvas en las que más coca requiere menos pobreza para producir perfil C, y un umbral de bosque entre 50 y 60 % que la distancia solo desplaza en los departamentos más alejados. La logística,

forzada a rectas y afectada por la colinealidad entre distancia e IPM (ρ = 0,79), invierte incluso el signo de la pobreza (Figura 7d). La red representa las interacciones, pero con 30 unidades espaciales el costo en varianza todavía anula esa ventaja, y ese es un argumento cuantitativo para migrar a municipio.

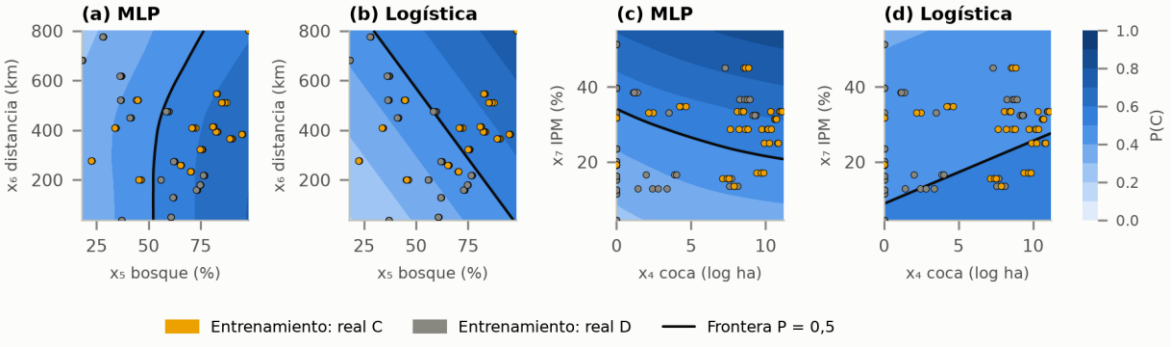


Figura 7: Superficies de dependencia parcial de P(C): bosque × distancia (a, b) y coca × pobreza (c, d) para el MLP y la logística. Línea negra: frontera P = 0,5; puntos: departamentos de entrenamiento (ámbar C, gris D)

6.4 Análisis de errores y síntesis

Los 14 errores en validación y prueba no son aleatorios. El 57 % son transiciones de perfil, frente al 5 % entre los aciertos, y el 57 % tiene s^C a ±10 puntos del umbral, frente al 18 %. En 2025 los 7 errores son C predichos como D, cinco de ellos transiciones D → C en el año de escalamiento (Meta, Magdalena, Cesar, Córdoba y Valle del Cauca). Arauca, que es C los seis años, recibe P ≈ 0,36: su perfil no se explica por coca (no tiene) ni por selva (34 %), sino por la presencia del ELN en la frontera, es decir, por x_3, la variable pendiente desde la Etapa 1. De las 10 transiciones, el MLP anticipa 2 y la persistencia ninguna, por construcción.

Tabla 5: Síntesis del diagnóstico técnico

Dimensión	Evidencia principal	Veredicto
Convergencia	Pérdida en meseta; gradiente estable; actualización $\approx 10^{-3}$	Converge a un mínimo estable
Estabilidad	CV del AUC 2,8 % (10 semillas); valle plano; 66 % unánimes	Estable; sensible en casos frontera
Generalización temporal	AUC 0,89 fuera de muestra 2023–2026; degrada con la distancia	Aceptable; sensible a la deriva (2025)
Generalización espacial	AUC 0,78 (logística 0,82, que gana en 17 de 20 particiones)	Débil: memoriza firmas departamentales
Sesgo–varianza	Brecha ≈0,2 sin cerrar; sobreajuste con más capacidad	Limitado por varianza: faltan unidades
No linealidad	Fronteras curvas coherentes con la U1, sin ventaja predictiva	Presente, aún no rentable con n = 171
Frente a la inercia	Persistencia AUC 0,96; 57 % de los errores son transiciones	No la supera sin memoria del perfil

6.5 Lectura para la decisión: proyección 2027

Para cerrar el ciclo con la pregunta de la Etapa 1, el modelo se reentrenó con todas las etiquetas 2021–2026 (ensamble de 5 semillas) y se alimentó con la información de 2026. Clasifica 10 departamentos como C consolidado (P ≥ 0,7: Guaviare, Nariño, Cauca, Caquetá, Antioquia, Norte de Santander y Chocó, más Vaupés, Amazonas y Guainía, con pocos datos), 13 en transición y 10 como D consolidado, el eje andino y urbano.

La traducción a capacidades sigue la Etapa 1: ISR, detección temprana y movilidad protegida donde domina C; portafolio flexible con monitoreo trimestral en transición, y orden público con capacidades mixtas en D. Sobre esa capa se superpone una alerta A/B cuando la proporción de eventos con explosivos o drones en 2025–2026 duplica el promedio nacional (12,7 %). Guaviare (14,4 %) y Cauca (13,4 %) requieren además evaluar C-UAS y detección de AEI, lo que recupera el hallazgo crítico de la Etapa 1 (§5.4) que la etiqueta binaria diluye.

En 10 departamentos, como Arauca, el modelo contradice el perfil observado en 2026: son casos de revisión en los que no conviene decidir solo con el modelo base. Es un insumo para priorizar, no un reemplazo del análisis de inteligencia.

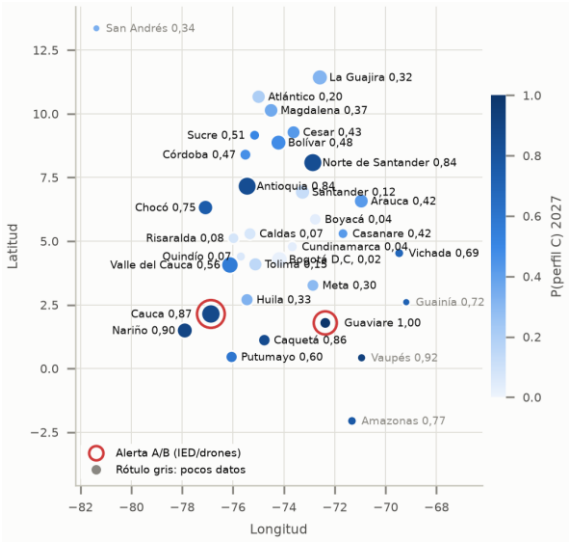


Figura 8: Probabilidad de perfil C proyectada para 2027 por departamento (centroides; tamaño proporcional a los eventos de 2026)

7. Oportunidades de mejora para la siguiente iteración

Las mejoras se derivan del diagnóstico y las dos más baratas se midieron antes de proponerlas (Tabla 6): **E1**, agregar la memoria del perfil $x_8 = s^C_{d,t-1}$ (versión compositiva de la "intensidad histórica" de x_1), y **E2**, promediar 5 redes con semillas distintas.

Tabla 6: Experimentos de mejora con predicciones fuera de muestra (validación temporal y espacial dejando un departamento fuera)

Modelo	AUC temporal	Log-loss temporal	AUC espacial	Log-loss espacial
Persistencia	0,965	0,380	0,918	0,420
Logística base (x_1–x_7)	0,875	0,448	0,821	0,530
MLP base (x_1–x_7)	0,892	0,436	0,782	0,605
MLP base + ensamble de 5 semillas (E2)	0,918	0,401	0,828	0,510
Logística + memoria x_8	0,922	0,353	0,899	0,397
MLP + memoria x_8 (E1)	0,933	0,362	0,878	0,466
MLP + memoria + ensamble (E1 + E2)	0,933	0,358	0,887	0,436

E1 es la mejora de mayor impacto: con memoria, los modelos superan a la persistencia en log-loss temporal (0,35–0,36 frente a 0,38) y, en el eje espacial, lo logra la logística con memoria (0,397 frente a 0,420). E2 reduce la debilidad espacial (AUC de 0,78 a 0,83) y deja al MLP a la par de la logística en departamentos nuevos (0,83 frente a 0,82), una diferencia menor que la variación entre particiones pero coherente con que el problema era varianza. En la proyección 2027 la memoria resuelve 5 de las 10 discrepancias con el perfil observado en 2026 (Arauca pasa de 0,42 a 0,59).

Tabla 7: Hoja de ruta priorizada de mejoras

#	Mejora	Evidencia que la motiva	Acción para la Unidad 3	Prioridad	Responsable
M1	Memoria y dinámica del perfil	Persistencia AUC 0,96; 57 % de los errores en transiciones; E1	Incorporar s^C_{t-1}, s^C_{t-2} y tendencia de eventos	Alta	Juan Diego
M2	Ensamble de redes	Varianza entre semillas; E2 (AUC espacial +0,05)	Promediar 5–10 redes en el modelo operativo	Alta	Juan Diego
M3	Migrar a municipio	Brecha espacial; curva de aprendizaje sin converger	Acceso académico al registro por evento de ACLED; coca SIMCI e IPM censal ya son municipales	Alta	Conjunta
M4	Completar x_3 y x_6 municipal	Error persistente en Arauca (frontera, ELN)	Contar actores distintos con actor1/actor2; distancia a cabecera con IGAC	Alta	Laura
M5	Recalibrar y elegir el umbral con varios años	Subestima P(C) fuera de muestra; umbral 0,17 no transferible	Platt o temperature scaling con predicciones 2023–2025	Media	Juan Diego
M6	Etiqueta por severidad u objetivo continuo	U1 §5.4 (A/B de bajo volumen y alto impacto); sin protestas A/B tampoco dominan	Regresión de s^C o eventos ponderados por fatalidades; reabrir 4 clases	Media	Laura
M7	Ajuste conjunto de capacidad, L2 y épocas	Sobreajuste con > 8 neuronas; época óptima variable	Búsqueda bayesiana con validación temporal anidada	Baja	Juan Diego

8. Trabajo colaborativo y organización del equipo

Mantuvimos la división acordada al cierre de la Etapa 1: Juan Diego lideró la implementación técnica (auditoría del export, MLP, bucle de entrenamiento, búsqueda de hiperparámetros y cálculo de métricas) y Laura la integración de fuentes externas (SIMCI/ODC, GFW y DANE), la interpretación estratégica y la lectura para la decisión. El panel, el diseño $t-1 \rightarrow t$, la respuesta a la retroalimentación de la Etapa 1 y la priorización de mejoras las decidimos en conjunto, y las doce decisiones quedaron en la bitácora del notebook con su alternativa descartada y su evidencia. Para la Unidad 3 acordamos empezar por los datos (M3 y M4), porque cambian la unidad de análisis, seguir con memoria y ensamble a escala municipal (M1 y M2) y cerrar con calibración, umbral y etiqueta por severidad (M5 y M6).

9. Conclusiones

1. El modelo base responde a la pregunta de la Etapa 1 con su misma variable objetivo, seis de sus siete predictoras más la letalidad derivada y la unidad de análisis comprometida, con un diseño $t-1 \rightarrow t$ que reproduce el momento real de la decisión. Quitar las protestas no recupera A ni B, así que la etiqueta C/D se sostiene.
2. Un MLP de una capa oculta, elegido por validación temporal, aprende una señal real (AUC fuera de muestra de 0,83–0,89 en años nuevos y 0,78 en departamentos nunca vistos, frente a 0,50 del azar), converge de forma estable y es reproducible entre semillas.
3. Lo que limita al modelo es la generalización espacial: con 30 departamentos la red está limitada por varianza, la logística la supera en 17 de 20 particiones y la no linealidad, visible en las fronteras, todavía no rinde en predicción sin más unidades ni la variable de actores (x_3).
4. El hallazgo central es la inercia: el perfil se repite el 86 % de las veces y las variables de la Etapa 1 explican *dónde* es probable cada perfil, pero no *cuándo* cambia; con memoria (E1) los modelos superan a la persistencia en log-loss temporal.

5. La proyección 2027 prioriza 10 departamentos C consolidados, 13 en transición y 10 D, con una alerta de explosivos y drones para Guaviare y Cauca que mantiene visible la amenaza de bajo volumen y alto impacto que motivó el proyecto.

Nota: usamos Claude (Anthropic) para resolver algunas dudas de que nos surgían en el proceso, validar el código y los conceptos estadísticos, encontrar por qué los resultados espaciales cambiaban cuando lo corríamos en Google Colab o en nuestros computadores, y para implementar los análisis adicionales que decidimos incluir (validación dejando un departamento fuera, etiqueta sin protestas y estabilidad de la logística), revisar la coherencia entre informe y notebook y proponer ajustes de redacción para ajustarnos a la extensión que se nos pidió, pero importante aclarar que revisamos y validamos cada resultado y cada cambio.

Nota 2: todos los datos numéricos y las gráficas de este informe provienen de la ejecución completa del notebook adjunto, que incluye los archivos de caché de coca y bosque para reproducir las cifras exactas. (Anexo: el notebook con los experimentos, ejecutado en Google Colab, es https://colab.research.google.com/drive/1loVOhd-83iIr0MdtLXrExY0DOdFRokFg?usp=sharing)

10. Referencias bibliográficas en APA 7

Bergmeir, C., & Benítez, J. M. (2012). On the use of cross-validation for time series predictor evaluation. *Information Sciences, 191*, 192–213. https://doi.org/10.1016/j.ins.2011.12.028

Bishop, C. M., & Bishop, H. (2024). *Deep learning: Foundations and concepts*. Springer.

Departamento Administrativo Nacional de Estadística (DANE). (2019). *Pobreza multidimensional por departamentos 2018: Resultados*. DANE.

Dietterich, T. G. (1998). Approximate statistical tests for comparing supervised classification learning algorithms. *Neural Computation, 10*(7), 1895–1923. https://doi.org/10.1162/089976698300017197

Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. *The Annals of Statistics, 29*(5), 1189–1232. https://doi.org/10.1214/aos/1013203451

Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep learning*. MIT Press.

Hansen, M. C., Potapov, P. V., Moore, R., Hancher, M., Turubanova, S. A., Tyukavina, A., … Townshend, J. R. G. (2013). High-resolution global maps of 21st-century forest cover change. *Science, 342*(6160), 850–853. https://doi.org/10.1126/science.1244693

Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The elements of statistical learning* (2.ª ed.). Springer.

He, K., Zhang, X., Ren, S., & Sun, J. (2015). Delving deep into rectifiers: Surpassing human-level performance on ImageNet classification. En *Proceedings of the IEEE International Conference on Computer Vision* (pp. 1026–1034).

Hornik, K. (1991). Approximation capabilities of multilayer feedforward networks. *Neural Networks, 4*(2), 251–257. https://doi.org/10.1016/0893-6080(91)90009-T

Kingma, D. P., & Ba, J. (2015). Adam: A method for stochastic optimization. En *International Conference on Learning Representations*. https://arxiv.org/abs/1412.6980

Ministerio de Defensa de Colombia. (2025). *Informe de gestión: modernización y transformación de las Fuerzas Militares*. Ministerio de Defensa Nacional.

Ministerio de Justicia y del Derecho – Observatorio de Drogas de Colombia. (2026). *Detección de cultivos de coca (hectáreas)* [Conjunto de datos]. Datos Abiertos Colombia. https://www.datos.gov.co/d/acs4-3wgp

Prechelt, L. (1998). Early stopping — but when? En G. B. Orr & K.-R. Müller (Eds.), *Neural networks: Tricks of the trade* (pp. 55–69). Springer. https://doi.org/10.1007/3-540-49430-8_3

Raleigh, C., Linke, A., Hegre, H., & Karlsen, J. (2010). Introducing ACLED: An armed conflict location and event dataset. *Journal of Peace Research, 47*(5), 651–660. https://doi.org/10.1177/0022343310378914

Roberts, D. R., Bahn, V., Ciuti, S., Boyce, M. S., Elith, J., Guillera-Arroita, G., … Dormann, C. F. (2017). Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure. *Ecography, 40*(8), 913–929. https://doi.org/10.1111/ecog.02881

World Resources Institute. (2025). *Global Forest Watch: Colombia tree cover loss by subnational region* [Conjunto de datos]. https://www.globalforestwatch.org