Modelo neuronal integrado para anticipar el perfil de amenaza tecnológica de los territorios colombianos y orientar la adopción de tecnologías militares

Redes Neuronales · Universidad de La Sabana · noviembre de 2026 · Sector elegido: seguridad y defensa
Proyecto Integrador, Etapa 3 · Laura Alejandra Díaz Sastoque (0000288870) y Juan Diego Saldarriaga Muñoz (0000287391)

Código: https://github.com/salda824/perfil-amenaza-tecnologica-u3

Repositorio privado por la licencia académica de ACLED; se da acceso al profesor como colaborador.

1. Planteamiento del problema y contexto

Colombia ejecuta en 2026 la mayor inversión de modernización militar de su historia sin un modelo basado en datos que indique qué tecnología desplegar en cada territorio (Ministerio de Defensa de Colombia, 2025). En la Etapa 1 (U1) formulamos la pregunta orientadora:

> ***¿Cómo orientar la adquisición, transferencia de tecnología y fabricación de sistemas de seguridad y defensa de las Fuerzas de Colombia en función del perfil de amenaza tecnológica predominante de los municipios colombianos según las variables de actividad armada histórica, geografía operacional y economías ilícitas, de modo que se optimice la inversión de recursos en búsqueda del bienestar de los colombianos y el desarrollo del país?***

La pregunta habla de municipios, pero el export gratuito de ACLED solo desagrega a departamento (hallazgo de la Etapa 1). Por eso la respondemos a esa escala y dejamos la migración a municipio como primera recomendación (R1). La formulación es la misma de la U2. Para cada departamento d y año t, la red estima con lo observado hasta el cierre de $t-1$ la probabilidad de que el perfil sea C (armas convencionales y emboscadas) o D (amenaza mixta): $s^{C}_{d,t}$ = eventos C / eventos totales, $y_{d,t} = 1[s^{C}_{d,t} \geq 0{,}5]$ (al menos la mitad de los eventos son C, igual que en la U2) y $\hat{p}_{d,t} = f_{\theta}(x_{d,t-1})$. Usamos el año anterior por dos motivos: las fatalidades de t salen de los mismos ataques que definen el perfil C, y el presupuesto de un año se asigna con lo observado hasta el cierre del anterior. La Tabla 1 resume lo que dejó cada etapa.

Tabla 1: Trayectoria del proyecto y hallazgo que condiciona cada etapa

Etapa	Resultado	Hallazgo que condiciona la siguiente
U1 · Formulación	Perfiles A/B/C/D con la regla del 50 %, 7 variables, ACLED agregado a departamento	Ningún departamento tiene perfil A o B dominante, así que la clasificación es C vs. D; 33 filas no bastan, así que se arma un panel departamento–año
U2 · Modelo base	MLP 7 → 16 → 1 (145 parámetros); AUC temporal 0,89; empata con la logística	Repetir el perfil del año anterior (persistencia: AUC 0,965 y log-loss 0,380 en la validación 2023–2026 de la U2) supera a la red; agregar ese perfil como variable (experimento E1) fue la mejora más grande
U3 · Integración	10 frentes de intervención, controles de datos, pipeline reproducible, prueba 2026 única	La referencia a superar pasa a ser la persistencia, cruda y calibrada; un modelo aporta sobre ella cuando anticipa cambios de perfil

Notación y siglas. ACLED: Armed Conflict Location & Event Data. UCDP GED: Uppsala Conflict Data Program, Georeferenced Event Dataset. SIMCI: Sistema Integrado de Monitoreo de Cultivos Ilícitos. GFW: Global Forest Watch. IGAC: Instituto Geográfico Agustín Codazzi. IPM: índice de pobreza multidimensional del DANE. ISR: inteligencia, vigilancia y reconocimiento. C-UAS: sistemas contra aeronaves no tripuladas. AEI: artefactos explosivos improvisados. Perfiles según el mapeo de subtipos de ACLED de la U1: A agrupa IED/landmine, Grenade, Suicide bomb y Chemical weapon; B, Air/drone strike; C, Armed clash, Attack, Shooting, Abduction, Looting/property destruction y Disrupted weapons use; D, protestas, disturbios, arrestos y el resto de subtipos. Un territorio D es, por tanto, uno donde la violencia armada directa no llega a la mitad de los eventos. Transición: cambio de perfil entre $t-1$ y t. Log-loss o BCE: entropía cruzada binaria media, $-\text{media}[y \log \hat{p} + (1-y)\log(1-\hat{p})]$. Brier: error cuadrático medio de $\hat{p}$. ECE: error de calibración esperado con 5 grupos de igual tamaño. MCC: coeficiente de correlación de Matthews. AUC: área bajo la curva ROC. EE: error estándar. IC95: intervalo de confianza del 95 %. PSI: índice de estabilidad poblacional. I1–I9: intervenciones de la U3 (Tabla 5). Dk: decisiones numeradas de la bitácora del cuaderno (D1–D10 de la U2, D11–D20 de la U3).

2. Descripción del dataset y preprocesamiento

2.1 Fuentes, panel y variables

La base es el export semanal de ACLED para Colombia (ACLED, 2026; Raleigh et al., 2010): 17.573 registros semana × departamento × subtipo de evento, hasta el 15 de agosto de 2026. Le sumamos la coca del censo SIMCI (Ministerio de Justicia y del Derecho, Observatorio de Drogas de Colombia, 2026), la cobertura arbórea de GFW (Hansen et al., 2013; World Resources Institute, 2025), el IPM del DANE (2019) y, en esta etapa, UCDP GED 26.1 (Sundberg y Melander, 2013; Uppsala Conflict Data Program, 2026) para contar actores armados. El panel tiene 171 filas departamento–año etiquetables: 30 departamentos, años 2021–2026 y al menos 10 eventos por celda (Guainía, San Andrés y Vaupés no tienen ninguna celda con 10 eventos). Hay 82 filas C (48 %) y 89 D; la prevalencia de C va

de 32 % en 2021 a 62 % en 2025 y es 48 % en 2026. El código de la U3 reconstruye el dataset de la U2 con las mismas etiquetas y una diferencia máxima de $1{,}7\times10^{-13}$ en las 7 predictoras, así que cualquier cambio posterior en las métricas viene de las intervenciones. La Tabla 2 muestra el estado de cada variable al cierre de la U3.

Tabla 2: Variables del modelo (todas medidas en t−1) y su estado al cierre de la U3

ID	Variable	Operacionalización	Fuente	Estado U3
x_1, x_2, x_{2b}	Eventos, fatalidades, letalidad	log(1 + anualizado); fatalidades/evento	ACLED	En el modelo (U2)
x_4–x_7	Coca, bosque, distancia, IPM	log(1 + ha); % de dosel ≥ 30 %; km del centroide a Bogotá (proxy de presencia estatal); IPM 2018 (%)	SIMCI, GFW, centroides ACLED, DANE	En el modelo (U2)
m_1	Memoria del perfil	$\tilde{s}^C$ contraída del año t−1	ACLED	Nueva, retenida (I1)
d_1	Semestre reciente	$\tilde{s}^C$ de las últimas 26 semanas de t−1	ACLED semanal	Nueva, retenida (I2)
m_2, m_3; d_2, d_3	Trayectoria y tendencias	$\tilde{s}^C$ en t−2 y su cambio; tendencias semestrales	ACLED	Evaluadas, no retenidas
x_3	Grupos armados activos	log(1 + actores no estatales distintos)	UCDP GED 26.1	Evaluada, no retenida (I3)
v_1, v_2	Vecindad	$\tilde{s}^C$ y eventos de los departamentos contiguos	ACLED + IGAC	Evaluada, no retenida (I4)

Las proporciones nuevas usan contracción bayesiana, $\tilde{s}^C = (C + 2)/(n + 4)$, que equivale a un prior Beta(2, 2): un semestre con pocos eventos queda cerca de 0,5 en vez de saltar a 0 o 1, y con 100 eventos el ajuste no pasa de 2 puntos. Todas las variables se estandarizan, z = (x − media)/desviación, con la media y la desviación del entrenamiento de cada pliegue. Preferimos estandarizar a normalizar al rango [0, 1] porque con 113–142 filas un solo valor extremo nuevo (la coca de Nariño, por ejemplo) movería el mínimo o el máximo y desplazaría toda la escala. Los conteos y las hectáreas conservan el logaritmo de la U2. La coca y el bosque del año *t*−1 se publican durante el año *t*; como cambian lento, tomamos ese rezago de publicación como un límite menor. La Figura 1a muestra la razón para agregar d_1: en el 74 % de las 19 transiciones de 2021–2025, el segundo semestre del año anterior ya se movía hacia el perfil nuevo.

La prueba de 2026 tiene solo 33 semanas. Recalculamos la etiqueta de 2021–2025 con las primeras 33 semanas de cada año: coincide con la del año completo en el 94,9 % de 136 celdas, y las 7 discrepancias tienen s^C a menos de 10 puntos del umbral (Figura 1b). Para 2026 esperamos entonces 1 o 2 etiquetas distintas de las del año cerrado, todas en la franja ambigua.

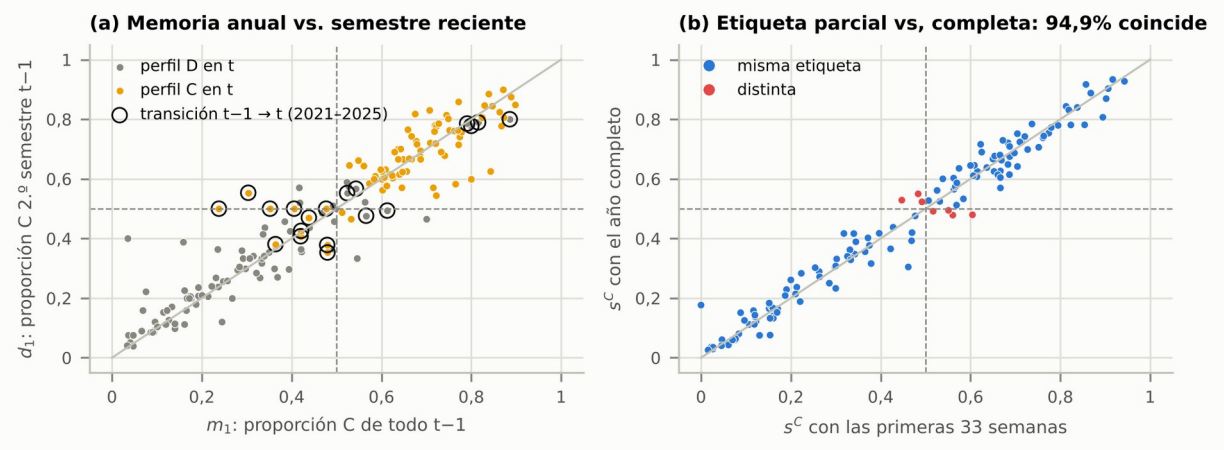


Figura 1: (a) En el 74 % de las 19 transiciones de 2021–2025 (sin la prueba 2026), el segundo semestre del año anterior (d_1) ya se movía hacia el nuevo perfil. (b) La etiqueta a la semana 33 coincide con la anual en el 94,9 % de las celdas 2021–2025

2.2 Controles experimentales de la preparación de datos

Pusimos a prueba cada decisión de preprocesamiento quitándola, o metiendo a propósito un error conocido, con el mismo protocolo y las mismas 5 semillas (Tabla 3, Figura 2).

Tabla 3: Controles de preparación de datos (Δ log-loss frente a la referencia de 0,310 y EE entre paréntesis; 5 semillas, origen móvil 2023–2025)

Control	Δ log-loss (EE)	Lectura
Sin estandarización	+5,780 (1,445)	La red no converge: distancias y porcentajes saturan ReLU y sigmoide, y la BCE de entrenamiento se queda en 7,1
Etiquetas barajadas (control negativo)	+0,506 (0,012)	AUC 0,32: con etiquetas al azar no hay señal que aprender, así que el desempeño medido viene de los datos
Sin pesos de clase	+0,015 (0,002)	En entrenamiento la prevalencia de C es 44 % y en los años validados llega a 62 %; sin pesos, la red se inclina hacia D
Mapeo alternativo de subtipos	+0,007 (0,001)	La regla de la U1 da mejor resultado
Sin contracción (α ≈ 0)	+0,002 (0,001)	Aporte pequeño, en la dirección esperada
Escalador con fuga (fuga deliberada)	−0,002 (0,001)	Mide la mejora artificial que daría una fuga; las pruebas automáticas la detectarían
Sin logaritmos	−0,012 (0,003)	No lo esperábamos: sale levemente mejor. No se cambia en esta iteración (regla 7 de §4.1); en el pliegue 2025 es peor
MIN_EVENTOS (umbral de eventos por celda) = 5 / 10 / 20	LL 0,300 / 0,307 / 0,338 (absolutas)	Log-loss en las mismas filas (≥ 20 eventos): 5 y 10 empatan, 20 empeora; se mantiene 10

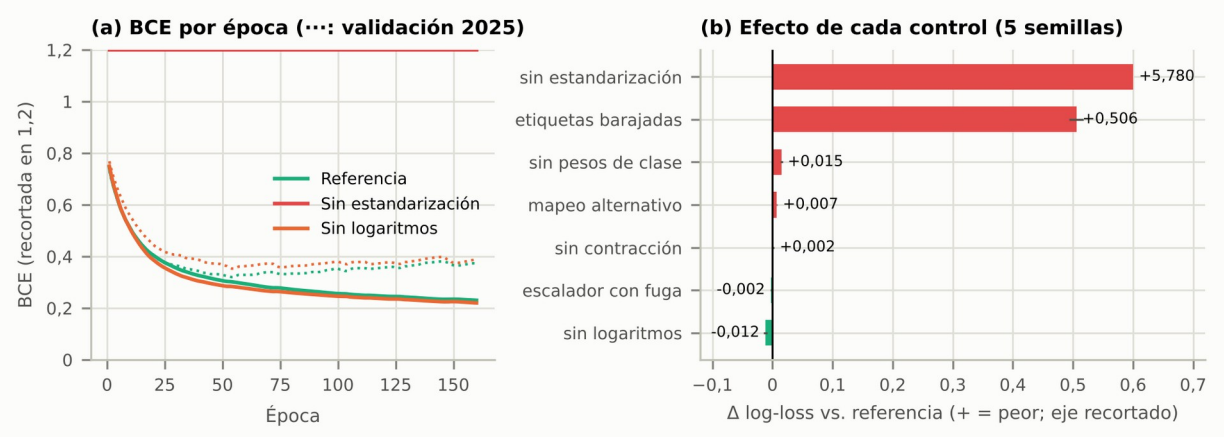


Figura 2: (a) Curvas de entrenamiento (—) y de validación 2025 (···) con y sin estandarización y logaritmos (semilla 1; la versión sin estandarizar no baja de 7,1). (b) Efecto de cada control sobre la log-loss fuera de muestra (5 semillas)

3. Arquitectura del modelo y justificación

El modelo final es un ensamble de 10 perceptrones multicapa con la misma estructura (API funcional de Keras): 9 entradas estandarizadas, una capa oculta de 16 neuronas ReLU y una salida sigmoide, con 177 parámetros por red. Son 1,25 parámetros por fila de entrenamiento (142 filas en 2021–2025); hay más parámetros que datos, y la L2 y el presupuesto fijo de pasos controlan el sobreajuste. Cada red se entrena con una semilla distinta y la predicción es el promedio de las 10 probabilidades. Frente a la U2, la arquitectura solo gana dos entradas, m_1 y d_1 (en verde en la Figura 3). La Tabla 4 resume la configuración.

También probamos una GRU y una CNN 1D sobre los cuatro trimestres de $t-1$ (log-loss 0,319 y 0,324, frente a 0,310), un MLP más profundo (16, 8; 0,309), un embedding de departamento, que codifica cada departamento como un entero y aprende un vector de 2 dimensiones (0,284; §6.6), y la regresión logística con las mismas variables (0,306). Las redes secuenciales tienen entre 393 y 665 parámetros y no encuentran en los trimestres más información de la que ya resume d_1, así que pierden por varianza.

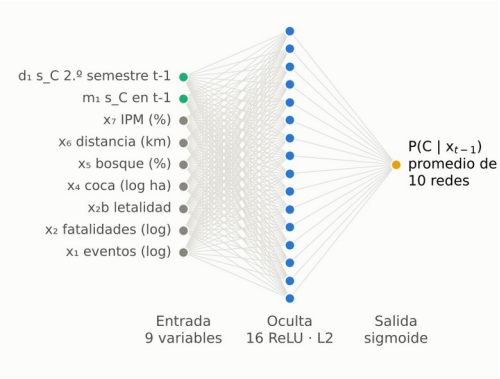


Figura 3: Arquitectura final (9 → 16 → 1, 177 parámetros por red; verde = variables nuevas)

Tabla 4: Configuración del modelo final y su justificación

Componente	Elección	Justificación técnica
Entrada	9 variables en t−1, estandarizadas con el entrenamiento	Las 7 de la U2 más m_1 y d_1, las únicas que pasaron la regla de retención (§5)
Capa oculta	16 neuronas ReLU, He normal	La rejilla de 48 configuraciones fue plana y ninguna alternativa elegida con 2023–2024 mejoró en 2025 (§5)
Salida y pérdida	Sigmoide; BCE ponderada por clase + L2 ($\lambda = 10^{-3}$)	Log-verosimilitud de Bernoulli (Goodfellow et al., 2016); sin pesos de clase la log-loss sube 0,015
Optimizador	Adam (Kingma y Ba, 2015), $\eta = 10^{-3}$, lote 16, 560 pasos fijos	Presupuesto mediano de la U2 (decisión D10, elegido con parada temprana sobre 2025); las curvas muestran que sigue cerca del óptimo (§4.2)
Ensamble	10 semillas, promedio de probabilidades	Reduce unas 6 veces la dispersión entre semillas (Lakshminarayanan et al., 2017)
Calibración y umbral	Sin recalibración; umbral 0,5 y bandas 0,3/0,7	Platt (1999) y temperatura (Guo et al., 2017) no mejoraron sin mirar el futuro, y el umbral óptimo cambia cada año

4. Proceso de entrenamiento y evaluación

4.1 Protocolo de evaluación

Las reglas 1 a 7 se fijaron antes de ejecutar las intervenciones. La regla 8 la agregamos durante ellas, al encontrar el caso del embedding de departamento (§6.6), y lo declaramos. La persistencia calibrada de la regla 3 se agregó después de la revisión del informe y no cambió el modelo adoptado.

1. Selección con validación de origen móvil (Bergmeir y Benítez, 2012): para v = 2023, 2024 y 2025 entrenamos con $t < v$ y predecimos v, lo que da 87 predicciones fuera de muestra. El escalador se ajusta en cada pliegue solo con su entrenamiento.
2. Prueba: 2026 se evalúa una sola vez, con las decisiones congeladas en `configuracion.json`. La U2 ya había reportado métricas sobre ese año, y lo dejamos dicho.
3. Referencia: la persistencia, $\hat{p}_{d,t} = s^{C}_{d,t-1}$ (AUC 0,973; log-loss 0,363), que por construcción no acierta ninguna transición. Como usa una proporción como si fuera una probabilidad, la comparamos también con su versión calibrada: una logística de dos parámetros sobre logit(m_1), entrenada solo con los años anteriores al predicho.
4. Métrica de decisión: la log-loss, que es una regla de puntuación propia (Gneiting y Raftery, 2007); AUC, Brier, ECE, MCC, exactitud y aciertos en transiciones sirven de apoyo.
5. Retención: cada variante se entrena con las mismas 5 semillas que su referencia y se queda si la mejora media de la log-loss supera un EE de la diferencia pareada, sin bajar el AUC más de 0,01. El EE es entre semillas, así que mide el ruido del entrenamiento y no el del muestreo de departamentos. En I4, cuya hipótesis es espacial, la regla se aplica a la validación espacial y se exige no empeorar la temporal.
6. Presupuesto fijo de 560 pasos de gradiente (D10), salvo cuando el presupuesto es lo que se estudia.
7. Los controles de datos de la §2.2 solo verifican decisiones heredadas: si uno favorece quitar una transformación, se reporta y queda para la siguiente iteración.
8. Una variante que mejora la log-loss solo porque se parece más a la persistencia (acierta menos transiciones) o porque no puede aplicarse a territorios nuevos queda documentada y no se adopta.

Las comparaciones pareadas usan bootstrap por departamento (2.000 remuestreos de departamentos completos) y la prueba de McNemar sobre los aciertos con umbral 0,5 (Dietterich, 1998).

4.2 Entrenamiento y curvas de desempeño

Cada red se entrena con el bucle explícito de tf.GradientTape de la U2, verificado allí contra model.fit (diferencia máxima de 2×10^{-6}; Géron, 2017). En cada paso, la red calcula $\hat{p}$ para un lote de 16 filas (propagación hacia adelante), evalúa la pérdida $L(\theta) = -(1/n)\,\Sigma_i\, \omega(y_i)[y_i \log \hat{p}_i + (1 - y_i)\log(1 - \hat{p}_i)] + \lambda\|W\|^2$, con $\omega(c) = n/(2n_c)$ y $\lambda = 10^{-3}$, obtiene $\partial L/\partial\theta$ por retropropagación y Adam actualiza pesos y sesgos con $\eta = 10^{-3}$ (franja inferior de la Figura 8). Con 113 filas de entrenamiento, 560 pasos son 70 épocas. En la U3 el bucle acepta además objetivo blando, salida multitarea y entradas secuenciales. La Figura 4 compara las curvas del modelo base y del final, entrenando con 2021–2024 y validando en 2025, con 5 semillas y tres veces el presupuesto. En el modelo final la BCE de validación en el paso 560 es 0,377 y su mínimo es 0,360, así que el presupuesto sigue cerca del óptimo; entrenar el triple la sube a 0,441 por sobreajuste. El modelo final baja tanto la BCE de entrenamiento (0,341 → 0,279) como la de validación (0,448 → 0,377), y la brecha entre ambas pasa de 0,107 a 0,097. Como la capacidad es la misma, la mejora viene de la información de entrada.

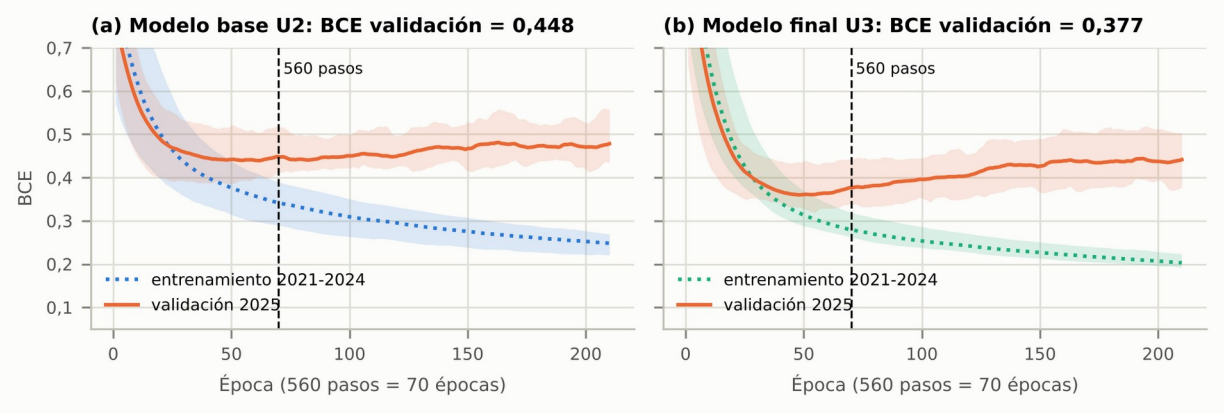


Figura 4: Curvas de aprendizaje con validación 2025 (media y rango de 5 semillas). Línea discontinua: presupuesto de 560 pasos (70 épocas)

5. Optimización realizada y comparación de resultados

Cada intervención responde a un hallazgo medido en la U2 y tiene una hipótesis que podía fallar (Tabla 5). Las de variables se aplicaron en cascada, cada una sobre la mejor especificación retenida hasta ese momento; las de modelo, sobre el conjunto de variables ya fijado. I9 tiene el último número porque la planteamos después de I1–I8, pero se evaluó junto con las de modelo.

Tabla 5: Del diagnóstico de la U2 a la decisión (Δ log-loss media entre 5 semillas pareadas, EE entre paréntesis; LL = log-loss)

#	Diagnóstico U2	Intervención	Resultado (2023–2025)	Decisión
I1	La inercia domina (persistencia AUC 0,965 en la U2)	Memoria m_1 (y m_2, m_3)	m_1: −0,036 (0,009); ΔAUC +0,017. m_2, m_3: +0,002	Retiene m_1
I2	Solo vista anual; escaladas de 2025	Semestre reciente d_1 (y d_2, d_3)	d_1: −0,037 (0,007); ΔAUC +0,013. d_2, d_3: +0,013	Retiene d_1
I3	Arauca mal clasificada; falta x_3	Actores armados (UCDP)	+0,025 (0,006); ΔAUC −0,014	No retiene
I4	Validación espacial débil	Vecindad v_1, v_2	Espacial +0,009 (0,004); temporal −0,004 (0,002)	No retiene (criterio espacial)
I5	20 % de celdas cerca del umbral	Objetivo blando s^C	+0,119 sin calibrar; +0,068 calibrado	No retiene
I9	A/B diluidas en la etiqueta	Salida multitarea A/B/C/D	P(C): +0,001; A/B peor que la persistencia	No retiene
–	MLP sin estructura temporal	GRU, CNN 1D, profundo, embedding, logística	+0,010; +0,014; 0,000; −0,026; −0,003 (§6)	No adopta (embedding: regla 8)
I6	Capacidad inestable entre análisis	Rejilla de 48 config. + anidada	Lo elegido en 2023–2024 empeora 2025 (0,41–0,42 vs. 0,36; ver texto)	Mantiene U2
I7	AUC 0,848 ± 0,024 entre semillas	Ensamble de 10 redes	LL −0,011 sin EE; banda 5–95 % de 0,053 a 0,009	Retiene (estabilidad)
I8	Subestima P(C); umbral no transfiere	Platt / temperatura; umbral	LL 0,298 → 0,302 en 2024–2025 (Platt hacia adelante)	No retiene

La rejilla de capacidad (4–32 neuronas), L2, activación (ReLU, tanh) y presupuesto (280–1.120 pasos) es plana (I6): 31 de 48 configuraciones quedan a menos de un EE de la mejor, y la vigente (puesto 18) está en esa banda. Para ver si elegir en la rejilla ayudaría, seleccionamos con 2023–2024 y medimos en 2025, una validación anidada de un solo pliegue externo. La mejor de 2023–2024 obtiene 0,423 y la elegida por la regla de 1 EE obtiene 0,411; la vigente obtiene 0,359 (Figura 5b; media de 3 semillas, frente a 0,377 con las 5 de la Figura 4). La comparación favorece a la vigente, porque su capacidad y su presupuesto se eligieron en la U2 con una validación que incluía 2025. Por eso no la leemos como prueba de que la vigente sea mejor: con 58 filas, la rejilla no ofrece una alternativa que se sostenga al año siguiente (Cawley y Talbot, 2010), y mantenemos la configuración de la U2 por parsimonia. En la calibración (I8), el parámetro de escala de Platt vale 1,31 en 2023 y 3,38 en 2024, y en 2025 no converge porque la red separa perfectamente las clases ese año (AUC = 1,0), aunque con umbral 0,5 clasifica mal seis escaladas. El umbral que maximiza el MCC es 0,20, 0,51 o 0,15 según el año. Por eso la incertidumbre se maneja en la decisión con las bandas 0,3/0,7 de la Etapa 2 y el umbral se deja en 0,5.

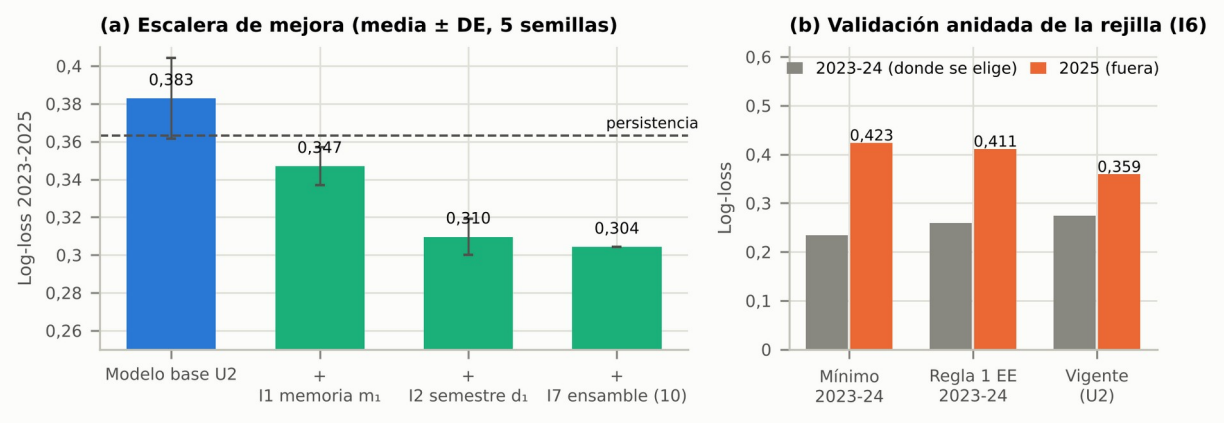


Figura 5: (a) Escalera de mejora: log-loss de una red individual (media ± DE de 5 semillas) al agregar m_1 y d_1, y del ensamble de 10; el modelo entregado en la U2 (semilla 42) tenía 0,407. (b) Validación anidada: lo que se elige con 2023–2024 es peor en 2025 que la configuración vigente, elegida en la U2 con una validación que incluía 2025

Tabla 6: Antes y después frente a los rivales (rival agregado tras la revisión; no cambió el modelo adoptado)*

Conjunto	Modelo	AUC	Log-loss	Brier	ECE	MCC	Exactitud	Sens. C / Espec. D	Transiciones
Origen móvil 2023–2025 (n = 87)	Persistencia	0,973	0,363	0,106	0,173	0,795	0,897	0,86 / 0,93	0 de 9
	Persistencia calibrada*	0,966	0,328	0,099	0,116	0,778	0,885	0,82 / 0,95	1 de 9
	Antes: base U2, semilla 42	0,913	0,407	0,132	0,084	0,659	0,816	0,68 / 0,95	2 de 9
	Antes: base U2, ensamble de 10	0,933	0,376	0,120	0,094	0,644	0,816	0,73 / 0,91	3 de 9
	Logística (mismas variables)	0,949	0,306	0,097	0,068	0,737	0,862	0,77 / 0,95	1 de 9
	Después: MLP U3 (ensamble de 10)	0,956	0,304	0,095	0,124	0,691	0,839	0,75 / 0,93	2 de 9
Prueba 2026 (n = 29), una sola vez	Persistencia	0,948	0,429	0,131	0,207	0,755	0,862	1,00 / 0,73	0 de 4
	Persistencia calibrada*	0,948	0,351	0,105	0,150	0,755	0,862	1,00 / 0,73	0 de 4
	Antes: base U2, semilla 42	0,852	0,524	0,166	0,104	0,517	0,759	0,71 / 0,80	1 de 4
	Antes: base U2, ensamble de 10	0,862	0,470	0,157	0,109	0,517	0,759	0,71 / 0,80	1 de 4
	Logística (mismas variables)	0,929	0,383	0,129	0,114	0,531	0,759	0,86 / 0,67	0 de 4
	Después: MLP U3 (ensamble de 10)	0,900	0,380	0,121	0,074	0,672	0,828	0,93 / 0,73	0 de 4

Frente al modelo de la U2 (una red, semilla 42, reentrenada con los 560 pasos fijos de la U3; la fase 2 de la U2 reportó 0,547 en 2026), la log-loss baja de 0,407 a 0,304 en selección (Δ −0,103; IC95 por departamento [−0,185; −0,033]) y de 0,524 a 0,380 en 2026 (Δ −0,144; IC95 [−0,270; −0,033]). La U2 había documentado que esa semilla quedó en la cola desfavorable, así que la comparamos también con la misma arquitectura base promediada sobre las mismas 10 semillas del modelo final (Tabla 6). Con ensamble en los dos lados, la log-loss baja de 0,376 a 0,304 en selección (Δ −0,072; IC95 [−0,114; −0,033]) y de 0,470 a 0,380 en 2026 (Δ −0,090; IC95 [−0,162; −0,024]); la mejora atribuible a m_1 y d_1 se mantiene con los dos criterios. Las cifras de selección salen de una cascada de unas 20 comparaciones sobre las mismas 87 predicciones y por eso son algo optimistas (Cawley y Talbot, 2010); 2026 es la estimación que no pasó por la selección.

6. Análisis crítico del desempeño

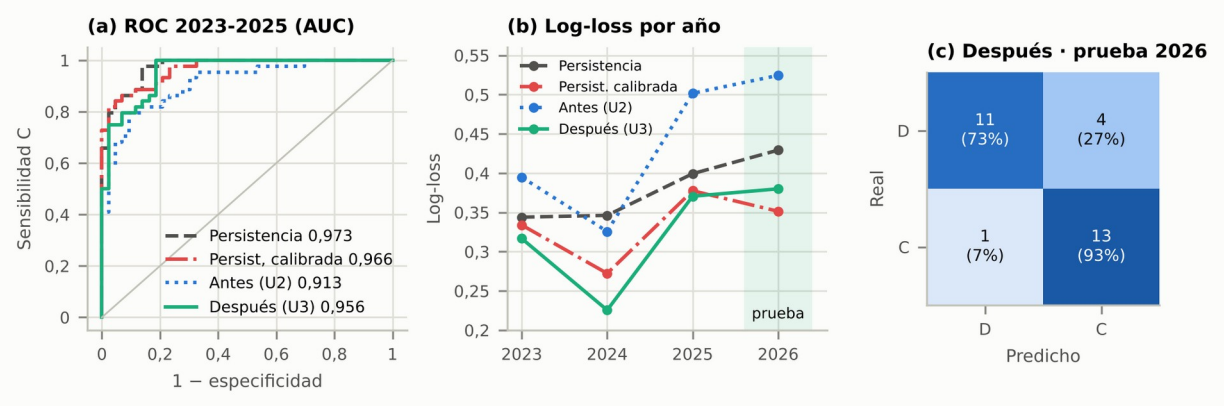


Figura 6: (a) Curvas ROC en 2023–2025. (b) Log-loss por año: el modelo final queda por debajo de la persistencia cruda en los cuatro años y de la calibrada en 2023–2025; en 2026 la calibrada es mejor. (c) Matriz de confusión del modelo final en la prueba 2026

6.1 Frente a la inercia

Frente a la persistencia cruda, el modelo baja la log-loss en 0,059 en selección (IC95 [−0,142; +0,028]; gana en el 92 % de los remuestreos) y en 0,049 en 2026 (IC95 [−0,162; +0,092]). La persistencia conserva el mejor AUC (0,973 y 0,948), así que ordena mejor los departamentos, y con umbral 0,5 también clasifica mejor (exactitud 0,897 frente a 0,839 en selección; acierta 7 casos que el modelo falla y el modelo 2 que ella falla, McNemar p = 0,18). La ventaja del modelo está en la calibración: la persistencia usa s^C como si fuera una probabilidad (ECE 0,173). Calibrada con una logística entrenada solo con años anteriores, la inercia obtiene 0,328 en selección y 0,351 en 2026 (Tabla 6). El modelo la supera en selección (Δ −0,024; IC95 [−0,096; +0,052]) y queda por encima en 2026 (Δ +0,029; IC95 [−0,055; +0,125]). La información útil está en la composición reciente (m_1 y d_1): a escala departamental, ni la red ni las variables estructurales agregan una ventaja demostrable sobre una inercia bien calibrada.

6.2 Matriz de confusión y regla de decisión

En 2026 el modelo clasifica bien 13 de 14 departamentos C y 11 de 15 D (Figura 6c; sensibilidad 0,93, especificidad 0,73, exactitud 0,83). Los 4 falsos positivos son exactamente las 4 desescaladas C → D (Bolívar, Chocó, Magdalena y Valle del Cauca): el modelo sigue la inercia y sobrestima C cuando el conflicto baja, con el riesgo de asignar ISR y movilidad protegida donde el perfil ya cambió. El único falso negativo es Cesar (P = 0,45), que cae en la banda de transición y recibiría portafolio flexible. La decisión usa bandas y no el umbral 0,5, así que las evaluamos contra el perfil observado. En 2023–2025, 71 de 87 filas caen en una banda consolidada y 66 de ellas aciertan (31 de 32 en C y 35 de 39 en D); en 2026, 24 de 29, con 21 aciertos (10 de 13 en C y 11 de 11 en D). Con la persistencia cruda, 42 de las 87 filas quedan en transición y la banda informa poco.

6.3 Departamentos nunca vistos

Con 5 grupos de departamentos (años ≤ 2025; Roberts et al., 2017), la log-loss del ensamble pasa de 0,445 en el modelo base a 0,351 en el final (0,476 → 0,373 si se compara red individual con red individual), por debajo de la persistencia (0,418). La U2 había reportado dejar un departamento fuera porque GroupKFold desempataba distinto según la versión de scikit-learn; desde la versión 1.6 el desempate es estable, y usamos 5 grupos por costo. Ese esquema, sin embargo, deja que la red aprenda de otros departamentos en el mismo año que predice, ventaja que la persistencia no tiene. Si además se entrena solo con años anteriores, que es el escenario real de un territorio nuevo al año siguiente, el modelo obtiene 0,361, la persistencia 0,363 (Δ −0,002; IC95 [−0,114; +0,130]), la persistencia calibrada 0,332 (Δ +0,029; IC95 [−0,075; +0,154]) y la logística 0,416. Las variables de composición transfieren mucho mejor que las estructurales de la U2, pero la ventaja frente a la inercia en territorios nuevos no está demostrada: la persistencia calibrada es la mejor de los cinco modelos.

6.4 Errores sistemáticos

De 19 errores en 2023–2026, el 58 % son transiciones (frente al 2 % entre los aciertos) y el 58 % tiene s^C a ±10 puntos del umbral (Figura 7a). El error estructural de la U2 se corrigió: Arauca recibe P(C) entre 0,77 y 0,85 en 2023–2026 y queda bien clasificada todos los años. Siguen fallando las escaladas D → C de 2025 (Córdoba, Magdalena, Cesar, Meta, Bolívar y Valle), las 4 desescaladas C → D de 2026, que ni el modelo final ni la persistencia aciertan (el modelo de la U2 acertó Magdalena, con P = 0,40), Huila, que es C en 2023 y 2024 y recibe 0,36 y 0,47, y Casanare, que tiene muy pocos eventos. En 2023–2026 el modelo final acierta 2 de 13 transiciones, el de la U2 3 (4 con ensamble), la persistencia calibrada 1 y la persistencia cruda ninguna: la mejora probabilística vino de los territorios estables y anticipar cambios de régimen sigue siendo la limitación principal.

6.5 Red neuronal frente a logística

Con las mismas variables, la logística empata en el eje temporal (Δ −0,002 en selección y −0,003 en 2026). La red aprende una frontera curva entre memoria y letalidad (Figura 7b): con 0,6 fatalidades por evento basta una memoria de ≈ 0,45 para esperar C, y sin letalidad hace falta ≈ 0,7. Como m_1 y la letalidad están correlacionadas (ρ = 0,84), la dependencia parcial extrapola fuera de la zona con datos, y la leemos solo donde hay puntos. Mantenemos el MLP por dos razones, ninguna concluyente: en departamentos no vistos el ensamble obtiene menos log-loss que la logística (0,351 frente a 0,373 con 5 grupos; 0,361 frente a 0,416 si además se respeta el tiempo, con IC95 de la diferencia [−0,236; +0,067]), y su frontera curva coincide con la hipótesis de no linealidad de la Etapa 1. La logística queda como control permanente.

6.6 Embedding de departamento

Cumplió la regla de retención (−0,026; EE 0,010), pero no lo adoptamos por la regla 8, que agregamos al ver este resultado: acertaba 0,8 de 9 transiciones (frente a 2,0) y en departamentos nuevos se reduce al MLP sin embedding (0,369 frente a 0,379 en el esquema espacial), así que su ganancia viene de efectos fijos memorizados. En 2026 obtuvo log-loss 0,314 y AUC 0,933, mejor que el modelo adoptado. No cambiamos la decisión, porque elegir con la prueba la dejaría sin valor como estimación. El resultado indica que los efectos fijos de cada departamento contienen información que las variables actuales no capturan (R7).

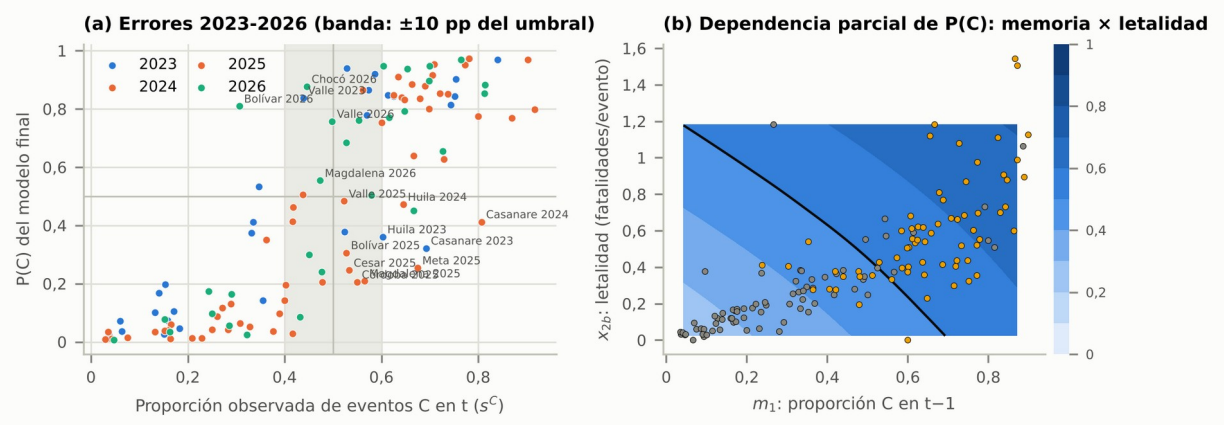


Figura 7: (a) P(C) predicha frente a la proporción observada, 2023–2026 (rótulos: errores en transiciones, Casanare y Huila). (b) Dependencia parcial de P(C) entre memoria y letalidad (línea negra: P = 0,5)

7. Integración final del modelo en un pipeline estructurado

En la U2 el cuaderno hacía todo el trabajo, y ese era el vacío principal frente a la guía. En la U3 el proceso está en el paquete `perfil_amenaza` del repositorio, con siete módulos: `config`, `datos`, `variables`, `modelo`, `evaluacion`, `pipeline` y `graficos`. El cuaderno importa el paquete, incluidas la regla de retención, la persistencia calibrada y las particiones de validación. Una sola orden ejecuta las 8 etapas de la Figura 8 en menos de un minuto, y cada etapa escribe un archivo que se puede revisar. La etapa 3 vuelve a evaluar la especificación congelada; la cascada de intervenciones se corrió en el cuaderno con la misma partición y la misma regla.

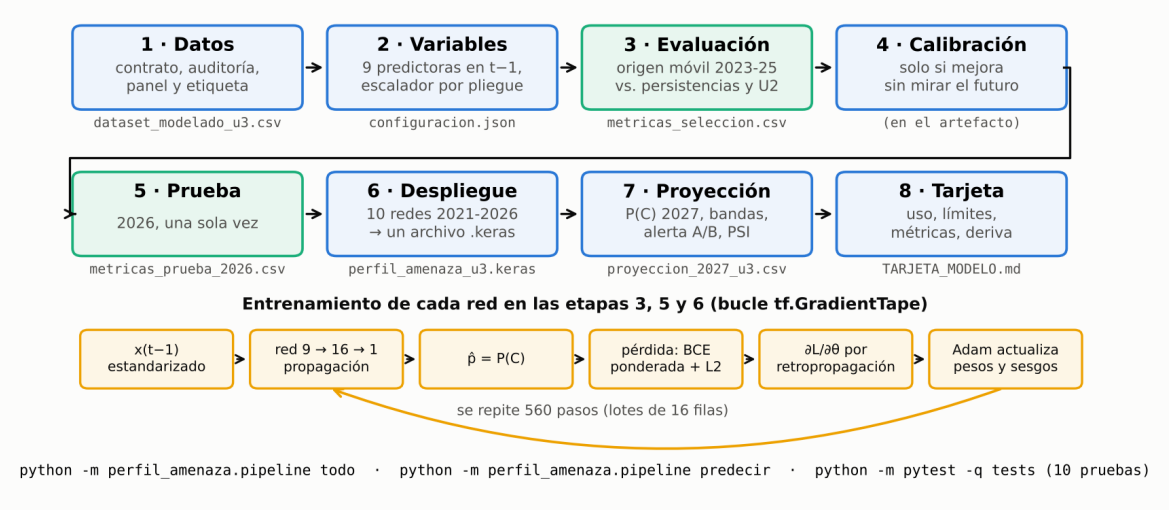


Figura 8: Pipeline integrado. Arriba, las 8 etapas y el archivo que deja cada una; las decisiones se congelan en configuracion.json antes de la prueba 2026. Abajo, el lazo de entrenamiento de cada red: error, gradiente y actualización de pesos

- El archivo `perfil_amenaza_u3.keras` (152 KB) es el artefacto de despliegue: contiene la estandarización (una capa Normalization con las medias y desviaciones del entrenamiento), las 10 redes, el promedio y la capa de calibración. Recibe las 9 variables en su escala original y devuelve P(C) sin necesitar el cuaderno.
- Las 10 pruebas automáticas (pytest) revisan el contrato de datos y su caso negativo, la ausencia de fuga temporal (multiplicar por 5 los eventos de 2024 no cambia ninguna predictora de las filas de 2024 y sí las de 2025), que el escalador y la capa Normalization del artefacto usen solo el entrenamiento, que la persistencia calibrada y la validación espacio-temporal no miren el año predicho, la regla de retención, el determinismo y la reproducción del dataset de la U2. Las 10 pasan.
- Las log-loss del pipeline (0,304 en selección y 0,380 en prueba) coinciden al cuarto decimal con las del cuaderno. El repositorio incluye `ejecutar_todo.bat`, que reproduce todo en Windows con un solo comando.
- La tarjeta del modelo (Mitchell et al., 2019) fija el uso previsto, los límites y el mantenimiento. El PSI compara la información de 2026 de los 30 departamentos del entrenamiento con las filas de entrenamiento (umbrales usuales: < 0,1 estable, 0,1–0,25 vigilar, > 0,25 deriva). Con 30 filas, el PSI tiene un piso de ruido alto: sin deriva, su percentil 95 está entre 0,21 y 0,39 según la variable. Solo la letalidad lo supera (PSI 0,45 frente a 0,37), así que la distribución de fatalidades por evento de 2026 difiere de la del entrenamiento. m_1 (0,23) y d_1 (0,17) caen en la franja de vigilancia, pero dentro del ruido de muestreo.

8. Del modelo a la decisión: priorización territorial 2027

Reentrenamos el ensamble con todas las etiquetas 2021–2026 y lo aplicamos, a través del artefacto, a la información de 2026. Las bandas de la Etapa 2 asignan C consolidado si P ≥ 0,7, transición si 0,3 ≤ P < 0,7 y D consolidado si P < 0,3 (Figura 9). Quedan 9 departamentos con datos suficientes como C consolidado (Guaviare, Nariño, Cauca, Caquetá, Putumayo, Antioquia, Norte de Santander, Vichada y Cesar), más Amazonas y Vaupés, que tienen menos de 10 eventos en 2026 y requieren revisión experta. Otros 11 quedan en transición (entre ellos San Andrés y Guainía, también con pocos datos) y 11 como D consolidado.

Las capacidades siguen la Etapa 1: ISR, detección temprana y movilidad protegida donde domina C; portafolio flexible y monitoreo trimestral en transición; orden público y capacidades mixtas en D. La alerta A/B se activa cuando la proporción de eventos con explosivos o drones de 2025–2026 es al menos el doble de la nacional (6,4 %, es decir, 12,7 %) y suma al menos 5 eventos. La cumplen Guaviare (14,4 %) y Cauca (13,4 %), donde conviene sumar C-UAS y detección de AEI.

Frente a la U2, 25 de 33 departamentos conservan su categoría. La proyección contradice el perfil observado en 2026 en 3

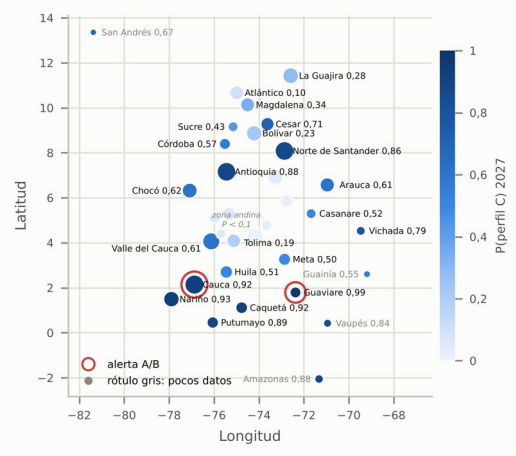


Figura 9: P(perfil C) proyectada para 2027 (centroides; tamaño según la raíz de los eventos anualizados de 2026; aro rojo: alerta A/B; rótulo gris: menos de 10 eventos). Sin rótulo, la zona andina con P < 0,1: Bogotá 0,01, Boyacá 0,02, Caldas 0,07, Cundinamarca 0,04, Quindío 0,06, Risaralda 0,07 y Santander 0,04

departamentos (Chocó, Valle del Cauca y Meta; en la U2 eran 10). Es una medida de cercanía a la inercia, no de acierto, y señala los casos que conviene revisar con inteligencia de campo. Chocó y Valle son desescaladas recientes con s^C de 2026 entre 0,45 y 0,50. La desviación entre las 10 redes crece donde el modelo duda (Chocó 0,16; Córdoba 0,12).

La información de 2026 cubre 33 semanas, así que d_1 resume febrero a agosto y no el segundo semestre. En 2020–2025, d_1 medido en esa ventana difiere del semestral en 0,084 en promedio (correlación 0,88). Meta (0,50), Huila (0,51) y Casanare (0,52) están en el umbral, así que la proyección debe repetirse al cerrar 2026.

9. Conclusiones técnicas y recomendaciones futuras

1. El modelo final responde la pregunta de la U1 a escala departamental, con la misma etiqueta, el mismo diseño $t-1 \rightarrow t$ y las mismas variables estructurales. Las dos variables nuevas llevan la "intensidad histórica" de la U1 a la composición reciente del conflicto.
2. De 10 frentes evaluados se retuvieron tres: m_1, d_1 y el ensamble. Las demás intervenciones no cumplieron la regla de retención, salvo la vecindad, que mejoró solo en el eje que no era el de su hipótesis, y el embedding, que la cumplió y se descartó por la regla 8. Con 58 filas de validación, la rejilla de hiperparámetros no ofreció una alternativa que se sostuviera al año siguiente.
3. Frente al modelo de la U2 la mejora es clara: con ensamble en los dos lados, la log-loss baja de 0,376 a 0,304 en selección y de 0,470 a 0,380 en 2026. Frente a la inercia cruda, la ventaja es de calibración. Frente a una inercia calibrada no está demostrada a escala departamental: el modelo gana por 0,024 en selección, pierde por 0,029 en 2026 y empata en territorios nuevos cuando se respeta el tiempo (0,361 frente a 0,363 de la persistencia y 0,332 de la persistencia calibrada).
4. El modelo anticipa 2 de 13 transiciones (el de la U2, 3) y no supera a una logística con las mismas variables en el eje temporal. Los efectos fijos de cada departamento (embedding) tienen información que las variables actuales no explican.
5. Para la pregunta de inversión, la evidencia sostiene para 2027 priorizar ISR, detección temprana y movilidad protegida en los 9 departamentos C consolidados con datos suficientes, sumar C-UAS y detección de AEI en Guaviare y Cauca, mantener portafolio flexible y monitoreo trimestral en los 11 de transición, y revisar con inteligencia de campo Chocó, Valle del Cauca y Meta. Como una inercia calibrada da casi la misma probabilidad a esta escala, el modelo aporta hoy un procedimiento reproducible que integra la composición reciente, las variables estructurales y la incertidumbre entre redes; su ventaja predictiva queda por probar a escala municipal (R1).

La Tabla 7 ordena las recomendaciones para la siguiente iteración.

Tabla 7: Recomendaciones priorizadas para la siguiente iteración

#	Recomendación	Evidencia	Acción concreta
R1	Migrar a municipio (registro por evento de ACLED)	Con 30 departamentos el modelo está limitado por varianza (U2) y en territorios nuevos empata con la inercia (§6.3)	Acceso académico al registro por evento; en el pipeline cambian `datos.py` y las constantes departamentales de `config.py`
R2	x_3 a escala municipal	El conteo anual por departamento empeoró el modelo (I3)	Medir entradas y salidas de grupos por municipio en lugar del conteo anual
R3	Señales adelantadas de transición	11 de 19 errores son transiciones	Variables mensuales del último trimestre, ceses al fuego y negociaciones
R4	Reentrenar cada año y vigilar el PSI con su piso de ruido	Prevalencia de C entre 41 % y 62 % en los años validados; en 2026 la letalidad supera el piso de ruido del PSI (§7)	Ejecutar el pipeline al cierre de cada año y decidir con bandas, sin umbral fijo
R5	Revisar logaritmos y MIN_EVENTOS	Controles de §2.2	Repetir la batería de controles con el dataset municipal
R6	Persistencia calibrada y logística como rivales permanentes	Empatan con el modelo dentro del ruido (§6)	Reportarlas en cada ejecución del pipeline y en la tarjeta del modelo
R7	Reevaluar el embedding cuando cierre 2026	Mejor en la prueba 2026 (0,314)	Candidato en la selección 2024–2026, con prueba en 2027; a escala municipal, reemplazarlo por x_3 y distancia

10. Trabajo en equipo y organización

Mantuvimos la división de las etapas anteriores y la llevamos a los cuatro roles que pide la guía (Tabla 8). Juan Diego propuso e implementó las intervenciones a partir del diagnóstico de la U2 y escribió el paquete; Laura revisó cada resultado contra las salidas del cuaderno, redactó las lecturas y propuso la lectura para la decisión (bandas, alerta A/B

y énfasis tecnológico). Las decisiones de protocolo las tomamos juntos antes de ejecutar: seleccionar solo con origen móvil y usar 2026 una vez, medir contra la persistencia con log-loss, la regla de retención y mantener la capacidad de la U2 si la rejilla no ofrecía una alternativa estable. Dos decisiones salieron de discutir resultados que no esperábamos: no adoptar el embedding (regla 8) y no cambiar los logaritmos aunque el control los favoreciera (regla 7). Después de la revisión del informe agregamos la persistencia calibrada y la validación espacio-temporal, sin cambiar el modelo. Las 20 decisiones (D1–D20) quedaron en la bitácora del cuaderno con su alternativa y su evidencia.

Tabla 8: Roles técnicos de la Unidad 3

Rol	Responsable	Entregables
Modelado	Juan Diego Saldarriaga Muñoz	Paquete perfil_amenaza, intervenciones I1–I9, rejilla y validación anidada, pipeline y pruebas
Evaluación	Conjunta (cálculo: Juan Diego; interpretación: Laura)	Protocolo y regla de retención, controles, antes vs. después, análisis de errores
Documentación	Laura Alejandra Díaz Sastoque	Interpretaciones, tarjeta del modelo, informe y README
Presentación	Laura (guion) y Juan Diego (demostración)	Video ejecutivo de 8 a 10 minutos y sustentación

11. Referencias bibliográficas en APA 7

Uso de IA. Usamos Claude (Anthropic) como apoyo en la programación del pipeline y del cuaderno y en la revisión de la redacción y la organización del informe. La propuesta del proyecto, la búsqueda y selección de datos, el análisis, las decisiones metodológicas y las conclusiones son del equipo, que ejecutó, revisó y verificó todos los resultados.

Armed Conflict Location & Event Data Project (ACLED). (2026). *ACLED data export: Colombia, agregado semanal por departamento y subtipo de evento (datos hasta el 15 de agosto de 2026)* [Conjunto de datos]. https://acleddata.com

Bergmeir, C., & Benítez, J. M. (2012). On the use of cross-validation for time series predictor evaluation. *Information Sciences, 191*, 192–213. https://doi.org/10.1016/j.ins.2011.12.028

Cawley, G. C., & Talbot, N. L. C. (2010). On over-fitting in model selection and subsequent selection bias in performance evaluation. *Journal of Machine Learning Research, 11*, 2079–2107. https://www.jmlr.org/papers/v11/cawley10a.html

Departamento Administrativo Nacional de Estadística (DANE). (2019). *Pobreza multidimensional por departamentos 2018: Resultados*. DANE.

Dietterich, T. G. (1998). Approximate statistical tests for comparing supervised classification learning algorithms. *Neural Computation, 10*(7), 1895–1923. https://doi.org/10.1162/089976698300017197

Géron, A. (2017). *Hands-on machine learning with Scikit-Learn and TensorFlow*. O'Reilly Media.

Gneiting, T., & Raftery, A. E. (2007). Strictly proper scoring rules, prediction, and estimation. *Journal of the American Statistical Association, 102*(477), 359–378. https://doi.org/10.1198/016214506000001437

Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep learning*. MIT Press.

Guo, C., Pleiss, G., Sun, Y., & Weinberger, K. Q. (2017). On calibration of modern neural networks. En *Proceedings of the 34th International Conference on Machine Learning* (PMLR 70, pp. 1321–1330). https://proceedings.mlr.press/v70/guo17a.html

Hansen, M. C., Potapov, P. V., Moore, R., Hancher, M., Turubanova, S. A., Tyukavina, A., Thau, D., Stehman, S. V., Goetz, S. J., Loveland, T. R., Kommareddy, A., Egorov, A., Chini, L., Justice, C. O., & Townshend, J. R. G. (2013). High-resolution global maps of 21st-century forest cover change. *Science, 342*(6160), 850–853. https://doi.org/10.1126/science.1244693

Kingma, D. P., & Ba, J. (2015). Adam: A method for stochastic optimization. En *International Conference on Learning Representations*. https://arxiv.org/abs/1412.6980

Lakshminarayanan, B., Pritzel, A., & Blundell, C. (2017). Simple and scalable predictive uncertainty estimation using deep ensembles. En *Advances in Neural Information Processing Systems 30* (pp. 6402–6413). Curran Associates.

Ministerio de Defensa de Colombia. (2025). *Informe de gestión: modernización y transformación de las Fuerzas Militares*. Ministerio de Defensa Nacional.

Ministerio de Justicia y del Derecho, Observatorio de Drogas de Colombia. (2026). *Detección de cultivos de coca (hectáreas)* [Conjunto de datos]. Datos Abiertos Colombia. https://www.datos.gov.co/d/acs4-3wgp

Mitchell, M., Wu, S., Zaldivar, A., Barnes, P., Vasserman, L., Hutchinson, B., Spitzer, E., Raji, I. D., & Gebru, T. (2019). Model cards for model reporting. En *Proceedings of the Conference on Fairness, Accountability, and Transparency* (pp. 220–229). https://doi.org/10.1145/3287560.3287596

Platt, J. (1999). Probabilistic outputs for support vector machines and comparisons to regularized likelihood methods. En A. J. Smola, P. Bartlett, B. Schölkopf, & D. Schuurmans (Eds.), *Advances in large margin classifiers* (pp. 61–74). MIT Press.

Raleigh, C., Linke, A., Hegre, H., & Karlsen, J. (2010). Introducing ACLED: An armed conflict location and event dataset. *Journal of Peace Research, 47*(5), 651–660. https://doi.org/10.1177/0022343310378914

Roberts, D. R., Bahn, V., Ciuti, S., Boyce, M. S., Elith, J., Guillera-Arroita, G., Hauenstein, S., Lahoz-Monfort, J. J., Schröder, B., Thuiller, W., Warton, D. I., Wintle, B. A., Hartig, F., & Dormann, C. F. (2017). Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure. *Ecography, 40*(8), 913–929. https://doi.org/10.1111/ecog.02881

Sundberg, R., & Melander, E. (2013). Introducing the UCDP Georeferenced Event Dataset. *Journal of Peace Research, 50*(4), 523–532. https://doi.org/10.1177/0022343313484347

Uppsala Conflict Data Program. (2026). *UCDP Georeferenced Event Dataset (GED) Global, versión 26.1* [Conjunto de datos]. Universidad de Uppsala. https://ucdp.uu.se/downloads/

World Resources Institute. (2025). *Global Forest Watch: Colombia tree cover loss by subnational region* [Conjunto de datos]. https://www.globalforestwatch.org