Modelo neuronal integrado para anticipar el perfil de amenaza tecnológica de los territorios colombianos y orientar la adopción de tecnologías militares

Sector Elegido: Seguridad y defensa
Proyecto Integrador, Etapa 3 - Laura Alejandra Díaz Sastoque (0000288870) & Juan Diego Saldarriaga Muñoz (0000287391)
Código: https://github.com/salda824/perfil-amenaza-tecnologica-u3

1. Planteamiento del problema y contexto

Colombia ejecuta en 2026 la mayor inversión de modernización militar de su historia sin un modelo basado en datos que oriente qué tecnología desplegar en cada territorio (Ministerio de Defensa de Colombia, 2025). En la Etapa 1 formulamos la pregunta orientadora:

¿Cómo orientar la adquisición, transferencia de tecnología y fabricación de sistemas de seguridad y defensa de las Fuerzas de Colombia en función del perfil de amenaza tecnológica predominante de los territorios, según su actividad armada histórica, geografía operacional y economías ilícitas, de modo que se optimice la inversión?

El problema se mantiene igual que en las etapas anteriores. Para cada departamento *d* y año *t*, la red estima, con lo observado hasta el cierre de $t-1$, la probabilidad de que el perfil sea **C** (armas convencionales y emboscadas) o **D** (amenaza mixta): $s^{C}_{d,t}$ = eventos C / eventos totales, $y_{d,t} = 1[s^{C}_{d,t} \geq 0{,}5]$, $\hat{p}_{d,t} = f_{\theta}(x_{d,t-1})$. El rezago evita la circularidad y reproduce el momento real de la decisión de inversión. La Tabla 1 resume qué dejó cada etapa y por qué la tercera se planteó como lo hicimos.

Tabla 1: Trayectoria del proyecto y hallazgo que condiciona cada etapa

Etapa	Resultado	Hallazgo que condiciona la siguiente
U1 · Formulación	Perfiles A/B/C/D con la regla del 50 %, 7 variables, ACLED agregado a departamento	Ningún departamento es A o B dominante → clasificación C vs. D; 33 filas no bastan → panel departamento–año
U2 · Modelo base	MLP 7 → 16 → 1 (145 parámetros); AUC temporal 0,89; equivalente a la logística	La persistencia del perfil (AUC 0,965; log-loss 0,380) supera a la red; la memoria (E1) es la palanca más fuerte
U3 · Integración	10 frentes de intervención, controles de datos, pipeline reproducible, prueba 2026 única	El rival es la persistencia, no el MLP base; el valor propio de un modelo está en anticipar cambios de perfil

2. Descripción del dataset y preprocesamiento

2.1 Fuentes, panel y variables

Fuentes. El núcleo es el export semanal de ACLED para Colombia (Raleigh et al., 2010): 17.573 registros semana × departamento × subtipo hasta el 15 de agosto de 2026. Se integran la coca del censo SIMCI (Observatorio de Drogas de Colombia, 2026), la cobertura arbórea de Global Forest Watch (Hansen et al., 2013), el IPM de DANE (2019) y, en esta etapa, UCDP GED 26.1 (Sundberg y Melander, 2013) para la variable de actores armados. **Unidad.** El panel tiene 171 filas departamento–año etiquetables (30 departamentos, 2021–2026, al menos 10 eventos por celda). El paquete de la U3 reconstruye el dataset de la U2 **al dígito**: las mismas etiquetas y una diferencia máxima de $1{,}7\times10^{-13}$ en las 7 predictoras, de modo que todo cambio posterior se debe a las intervenciones. La Tabla 2 muestra el estado de cada variable al final de la U3.

Tabla 2: Variables del modelo (todas medidas en t−1) y su estado al cierre de la U3

ID	Variable	Operacionalización	Fuente	Estado U3
x_1, x_2, x_{2b}	Eventos, fatalidades, letalidad	log(1 + anualizado); fatalidades/evento	ACLED	En el modelo (U2)
x_4–x_7	Coca, bosque, distancia, IPM	Igual que la U2	SIMCI, GFW, centroides, DANE	En el modelo (U2)
$\mathbf{m_1}$	Memoria del perfil	$\tilde{s}^{C}$ contraída del año t−1	ACLED	**Nueva, retenida (I1)**
$\mathbf{d_1}$	Semestre reciente	$\tilde{s}^{C}$ de las últimas 26 semanas de t−1	ACLED semanal	**Nueva, retenida (I2)**
m_2, m_3; d_2, d_3	Trayectoria y tendencias	$\tilde{s}^{C}$ en t−2 y cambio; tendencias semestrales	ACLED	Evaluadas, no retenidas
x_3	Grupos armados activos	log(1 + actores no estatales distintos)	UCDP GED 26.1	Evaluada, no retenida (I3)
v_1, v_2	Vecindad	$\tilde{s}^{C}$ y eventos de los departamentos contiguos	ACLED + IGAC	Evaluada, no retenida (I4)

Representación. Las proporciones nuevas se calculan con **contracción bayesiana**, $\tilde{s}^{C} = (C + 2)/(n + 4)$, equivalente a un prior Beta(2, 2). Así, un semestre con pocos eventos no produce proporciones extremas, y con 100 eventos el ajuste no pasa de 2 puntos. Todas las variables se estandarizan con media y desviación calculadas **solo con el entrenamiento de cada pliegue**. Los conteos y las hectáreas mantienen el logaritmo de la U2.

Control de la etiqueta parcial. La prueba de 2026 tiene solo 33 semanas. Recalculamos la etiqueta de 2021–2025 con las primeras 33 semanas de cada año y coincide con la del año completo en el **94,9 %** de 136 celdas. Las 7 discrepancias tienen todas s^C a menos de 10 puntos del umbral (Figura 1b). En 2026 se esperan entonces 1 o 2 etiquetas cambiadas, y todas en la franja ambigua.

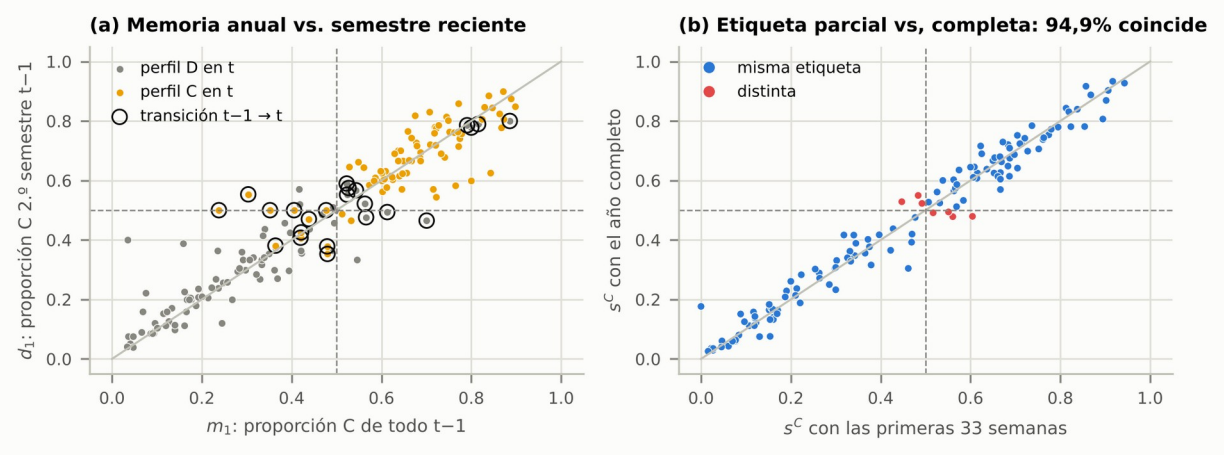


Figura 1: (a) En el 70 % de las 23 transiciones, el segundo semestre del año anterior (d_1) ya se movía hacia el nuevo perfil. (b) La etiqueta a la semana 33 coincide con la anual en el 94,9 % de las celdas 2021-2025

2.2 Controles experimentales de la preparación de datos

Cada decisión de preprocesamiento se puso a prueba quitándola, o introduciendo a propósito un error conocido, con el mismo protocolo y las mismas 5 semillas (Tabla 3, Figura 2).

Tabla 3: Controles de preparación de datos (Δ log-loss frente a la referencia de 0,310; 5 semillas, origen móvil 2023-2025)

Control	Δ log-loss (EE)	Lectura
Sin estandarización	+5,780 (1,445)	No converge: distancias y porcentajes saturan ReLU y sigmoide; BCE de entrenamiento fija en 7,1
Etiquetas barajadas (cordura)	+0,506 (0,012)	AUC 0,32: el desempeño medido viene de señal real, no del protocolo
Sin pesos de clase	+0,015 (0,002)	Con prevalencias de C entre 41 % y 62 %, la red se inclina hacia D
Mapeo alternativo de subtipos	+0,007 (0,001)	La regla de la U1 se sostiene
Sin contracción (α ≈ 0)	+0,002 (0,001)	Aporte pequeño, en la dirección esperada
Escalador con fuga (control negativo)	−0,002 (0,001)	Cuantifica la mejora artificial que daría una fuga; las pruebas automáticas la impiden
Sin logaritmos	−0,012 (0,003)	No anticipado: levemente mejor. No se cambia en esta iteración (regla 7, §4.1); en el pliegue 2025 es peor
MIN_EVENTOS = 5 / 10 / 20	0,300 / 0,307 / 0,338	Log-loss en las mismas filas (≥ 20 eventos): 5 ≈ 10 y 20 empeora; se mantiene 10

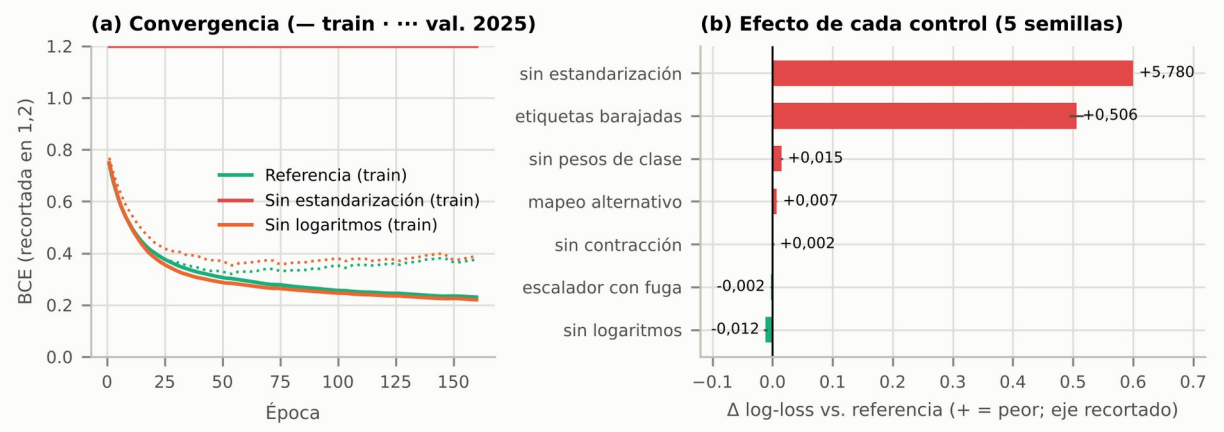


Figura 2: (a) Curvas de entrenamiento con y sin cada transformación (pliegue 2025; la versión sin estandarizar no baja de 7,1). (b) Efecto de cada control sobre la log-loss fuera de muestra

3. Arquitectura del modelo y justificación

El modelo final es un **ensamble de 10 perceptrones multicapa** idénticos en estructura (API funcional de Keras): 9 entradas estandarizadas, una capa oculta de 16 neuronas ReLU y una salida sigmoide, con 177 parámetros por red (1,25 por observación). Cada red se entrena con una semilla distinta y la predicción es el promedio de las 10 probabilidades. Es la misma arquitectura de la U2 con dos entradas más (m_1 y d_1, en verde en la Figura 3).

La arquitectura no se mantuvo por inercia. Se compararon una **GRU** y una **CNN 1D** sobre los cuatro trimestres de $t-1$ (log-loss 0,319 y 0,324, frente a 0,310), un **MLP profundo** (16, 8; 0,309, empate), un **embedding de departamento** (0,284, §6) y la **logística** con las mismas variables (0,306). Las redes secuenciales pagan en varianza sus 393–665 parámetros sin encontrar en los trimestres más información que la que ya resume d_1.

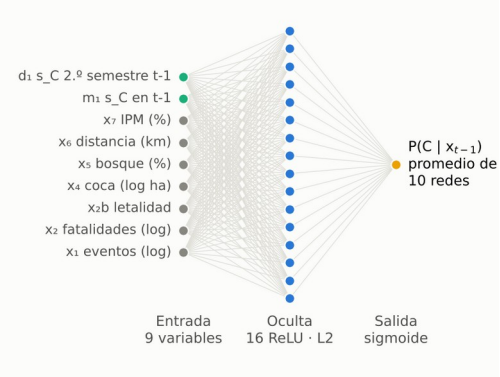


Figura 3: Arquitectura final (9 → 16 → 1, 177 parámetros por red; verde = variables nuevas)

Tabla 4: Configuración del modelo final y su justificación

Componente	Elección	Justificación técnica
Entrada	9 variables en t−1, estandarizadas con el entrenamiento	7 de la U2 + m_1, d_1 (únicas que superaron la regla de retención, §5)
Capa oculta	16 neuronas ReLU, He normal	La rejilla de 48 configuraciones fue plana y la validación anidada mostró que elegir otra no transfiere (§5)
Salida y pérdida	Sigmoide; BCE ponderada por clase + L2 ($\lambda = 10^{-3}$)	Log-verosimilitud Bernoulli (Goodfellow et al., 2016); sin pesos de clase la log-loss sube 0,015
Optimizador	Adam, $\eta = 10^{-3}$, lote 16, 560 pasos fijos	Presupuesto mediano de la U2 (D10); las curvas confirman que sigue cerca del óptimo (§4)
Ensamble	10 semillas, promedio de probabilidades	Reduce 6 veces la dispersión entre semillas (Lakshminarayanan et al., 2017)
Calibración y umbral	Sin recalibración; umbral 0,5 y bandas 0,3/0,7	Platt y temperatura no mejoraron sin mirar el futuro; el umbral óptimo cambia cada año

4. Proceso de entrenamiento y evaluación

4.1 Protocolo fijado antes de ver resultados

Selección. Validación de origen móvil (Bergmeir y Benítez, 2012): para v = 2023, 2024 y 2025 se entrena con $t < v$ y se predice v, lo que da 87 predicciones fuera de muestra. **Prueba.** 2026 se evalúa una sola vez, con todo congelado en `configuracion.json`. Lo declaramos: la U2 ya había reportado 2026. **Rival.** La persistencia, $\hat{p}_{d,t} = s^{C}_{d,t-1}$ (AUC 0,973; log-loss 0,363), que acierta 0 transiciones por construcción. **Métrica de decisión.** Log-loss, una regla de puntuación propia (Gneiting y Raftery, 2007), con AUC, Brier, ECE, MCC y aciertos en transiciones como apoyo. **Regla de retención.** Cada variante se entrena con las mismas 5 semillas que su referencia y se retiene si la mejora media de la log-loss supera un error estándar de la diferencia pareada, sin bajar el AUC más de 0,01. **Reglas 7 y 8.** Los controles de datos verifican, no seleccionan. Una variante que gana solo porque se parece más a la persistencia, o porque no puede aplicarse a territorios nuevos, se documenta pero no se adopta. Las comparaciones pareadas usan bootstrap por departamento y McNemar (Dietterich, 1998).

4.2 Entrenamiento y curvas de desempeño

Cada red se entrena con el bucle explícito de tf.GradientTape verificado en la U2 frente a model.fit (diferencia máxima 2×10^{-6}), generalizado en el paquete para objetivo blando, salida multitarea y entradas secuenciales. La Figura 4 compara las curvas del modelo base y del final, entrenando con 2021–2024 y validando en 2025, con 5 semillas y tres veces el presupuesto. En el modelo final, la BCE de validación en el paso 560 es **0,377**, frente a un mínimo de 0,360: el presupuesto sigue cerca del óptimo, y entrenar el triple la sube a 0,441 (sobreajuste). El modelo final baja a la vez la BCE de entrenamiento (0,341 → 0,279) y la de validación (0,448 → 0,377), y reduce la brecha entre ambas (0,107 → 0,097). No es una red más flexible que memoriza más, es una red mejor informada.

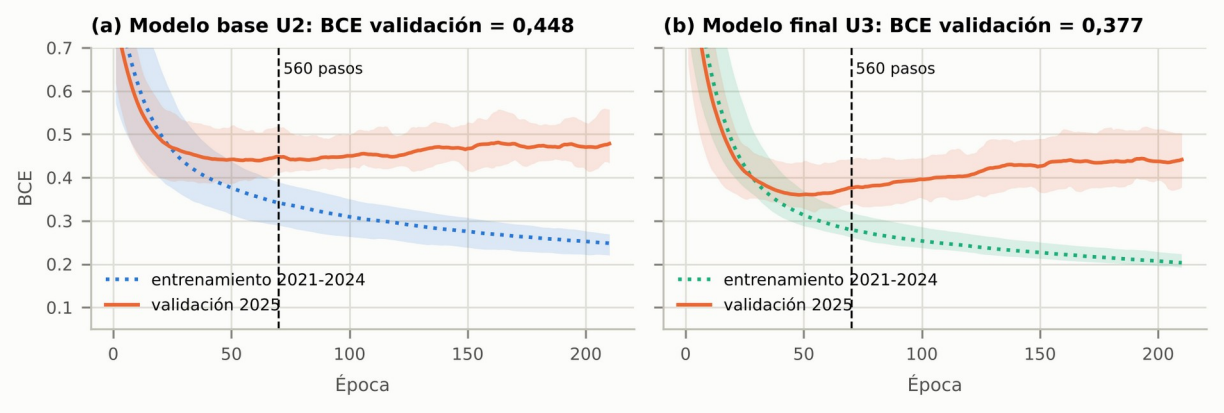


Figura 4: Curvas de aprendizaje con validación 2025 (media y rango de 5 semillas). Línea discontinua: presupuesto de 560 pasos

5. Optimización realizada y comparación de resultados

Cada intervención responde a un hallazgo medido en la U2 y tiene una hipótesis refutable. Las de variables se aplicaron en cascada (cada una sobre la mejor especificación retenida) y las de modelo, sobre el conjunto de variables ya fijado (Tabla 5).

Tabla 5: Del diagnóstico de la U2 a la decisión (Δ log-loss media entre 5 semillas pareadas; EE entre paréntesis)

#	Diagnóstico U2	Intervención	Resultado (2023-2025)	Decisión
I1	La inercia domina (persistencia AUC 0,965)	Memoria m_1 (y m_2, m_3)	m_1: −0,036 (0,009); AUC +0,017. m_2, m_3: +0,002	**Retiene m_1**
I2	Solo vista anual; escaladas de 2025	Semestre reciente d_1 (y d_2, d_3)	d_1: −0,037 (0,007); AUC 0,951. d_2, d_3: +0,013	**Retiene d_1**
I3	Arauca mal clasificada; falta x_3	Actores armados (UCDP)	+0,025 (0,006); AUC −0,014	No retiene
I4	Validación espacial débil	Vecindad v_1, v_2	Temporal −0,004 (0,002); espacial +0,009	No retiene
I5	20 % de celdas cerca del umbral	Objetivo blando s^C	+0,119 sin calibrar; +0,068 calibrado	No retiene
I9	A/B diluidas en la etiqueta	Salida multitarea A/B/C/D	P(C): +0,001; A/B peor que la persistencia	No retiene
–	MLP sin estructura temporal	GRU, CNN 1D, profundo, embedding	+0,010; +0,014; 0,000; −0,026 (§6)	No adopta
I6	Capacidad inestable entre análisis	Rejilla de 48 config. + anidada	Elegido en 2023-24 empeora 2025 (0,41–0,42 vs. 0,36)	Mantiene U2
I7	AUC 0,848 ± 0,024 entre semillas	Ensamble de 10 redes	LL −0,011; banda 5-95 % de 0,053 a 0,009	**Retiene**
I8	Subestima P(C); umbral no transfiere	Platt / temperatura; umbral	LL 0,298 → 0,302 (Platt hacia adelante)	No retiene

La lección de I6. La rejilla de capacidad (4–32 neuronas), L2, activación (ReLU, tanh) y presupuesto (280–1.120 pasos) es plana: 31 de 48 configuraciones quedan dentro de un error estándar de la mejor. La **validación anidada** pone a prueba el propio proceso de selección (Cawley y Talbot, 2010). La configuración con mejor log-loss en 2023–2024 obtiene 0,423 en 2025, la elegida por la regla de 1 EE obtiene 0,411 y la vigente de la U2 obtiene **0,359** (Figura 5b). Con 58 filas de validación, optimizar hiperparámetros ajusta ruido. **I8.** Ajustado año por año, Platt da una escala de 1,31 en 2023 y 3,38 en 2024, y diverge en 2025, cuando la red ordena sin errores. El umbral que maximiza el MCC es 0,20, 0,51 y 0,15 según el año. La incertidumbre se gestiona en la decisión, con las bandas 0,3/0,7 de la Etapa 1, no con un umbral ajustado.

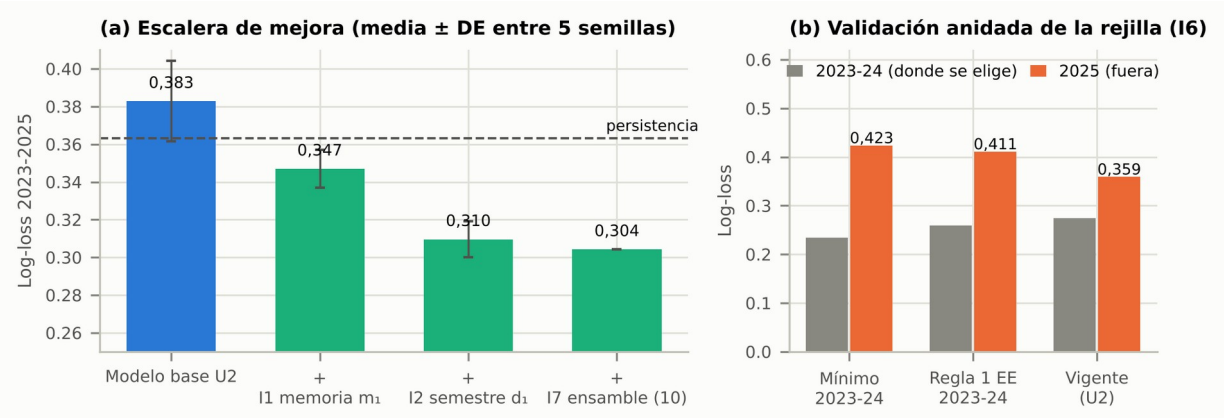


Figura 5: (a) Escalera de mejora: solo se retuvieron m_1, d_1 y el ensamble. (b) Validación anidada: lo que se elige con 2023-2024 es peor en 2025 que la configuración vigente

Tabla 6: Antes (modelo base U2, semilla 42) vs. después (modelo final U3) frente a la persistencia y la logística con las mismas variables

Conjunto	Modelo	ROC-AUC	Log-loss	Brier	ECE	MCC	Transiciones
Origen móvil 2023-2025 (n = 87)	Persistencia	0,973	0,363	0,106	0,173	0,795	0 de 9
	Antes: MLP base U2	0,913	0,407	0,132	0,084	0,659	2 de 9
	Logística (mismas variables)	0,949	0,306	0,097	0,068	0,737	1 de 9
	Después: MLP U3 (ensamble)	**0,956**	**0,304**	**0,095**	0,124	0,691	2 de 9
Prueba 2026 (n = 29), una sola vez	Persistencia	0,948	0,429	0,131	0,207	0,755	0 de 4
	Antes: MLP base U2	0,852	0,524	0,166	0,104	0,517	1 de 4
	Logística (mismas variables)	0,929	0,383	0,129	0,114	0,531	0 de 4
	Después: MLP U3 (ensamble)	0,900	**0,380**	**0,121**	**0,074**	0,672	0 de 4

Antes vs. después. En selección, la log-loss baja de 0,407 a 0,304 (Δ −0,103; IC95 por departamento [−0,185; −0,033]), el Brier de 0,132 a 0,095 (IC [−0,068; −0,009]) y el AUC sube de 0,913 a 0,956 (IC [+0,005; +0,105]). En la prueba 2026, la log-loss baja de 0,524 a 0,380 (Δ −0,144; IC [−0,270; −0,033]), y el modelo queda mejor calibrado que las alternativas (ECE 0,074). La mejora es significativa frente al modelo de la U2 en los dos conjuntos.

6. Análisis crítico del desempeño

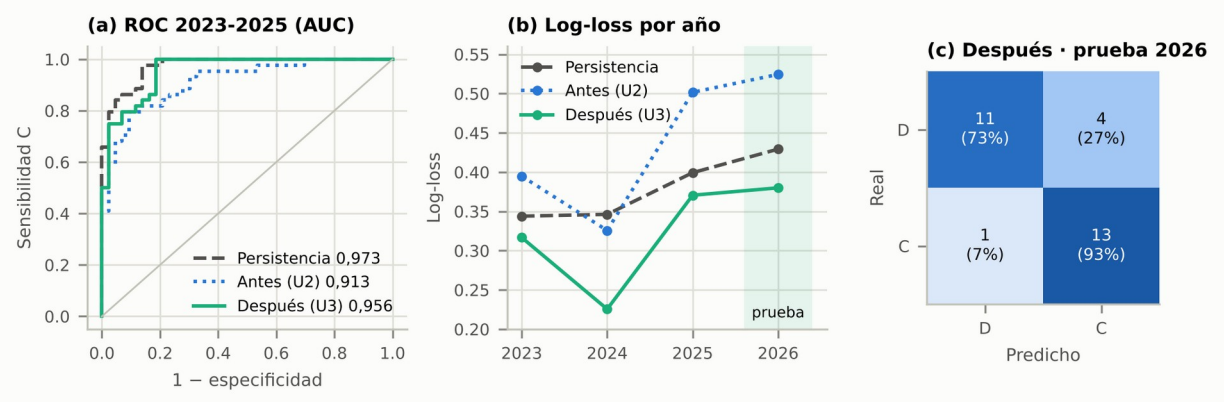


Figura 6: (a) Curvas ROC en 2023-2025. (b) Log-loss por año: el modelo final supera a la persistencia en los cuatro años. (c) Matriz de confusión del modelo final en la prueba 2026

- **Frente a la inercia, la mejora es probable pero no concluyente.** En selección, Δ log-loss = −0,059 frente a la persistencia (IC95 [−0,142; +0,028]; el modelo gana en el 92 % de los remuestreos). En 2026, Δ = −0,049 (IC [−0,162; +0,092]). La persistencia conserva el mejor AUC (0,973 y 0,948): ordena mejor, pero sus probabilidades son peores (ECE 0,173 y 0,207), porque usa s^C como si fuera una probabilidad. Con 30 departamentos, la conclusión honesta es que el modelo supera a la inercia en calidad probabilística y no en ordenamiento.
- **La debilidad espacial de la U2 quedó resuelta.** Con validación agrupada por departamento (Roberts et al., 2017), la log-loss en territorios nunca vistos pasa de 0,475 (modelo base) a **0,351**, mejor que la persistencia (0,418; Δ −0,067, IC [−0,135; +0,003]). Las variables estructurales casi constantes funcionaban como identificadores. Con información de composición, la red aprende una relación que se transfiere: es el argumento cuantitativo para escalar a municipio.
- **Errores sistemáticos.** De 19 errores en 2023–2026, el 58 % son transiciones (frente al 2 % entre los aciertos) y el 58 % tiene s^C a ±10 puntos del umbral (Figura 7a). Se corrigió el error estructural de la U2: Arauca recibe P(C) entre 0,77 y 0,85 en 2023–2026, todos C. Persisten las escaladas D → C de 2025 (Córdoba, Magdalena, Cesar, Meta, Bolívar y Valle), las desescaladas C → D de 2026 (Bolívar, Chocó, Magdalena y Valle, las 4 transiciones de la prueba, que ningún modelo acierta) y Casanare, con muy pocos eventos. El modelo acierta 2 de 13 transiciones y la persistencia 0: anticipar cambios de régimen sigue siendo la limitación principal.
- **¿Aporta la red neuronal?** Con las mismas variables, la logística empata (Δ −0,002 en selección; −0,003 en 2026). La no linealidad aparece en la forma (Figura 7b): la frontera entre memoria y letalidad es curva, y con 0,6 fatalidades por evento basta una memoria de ≈ 0,45 para esperar C (sin letalidad hacen falta ≈ 0,7). Pero no aparece en el desempeño. Se mantiene el MLP por coherencia con la U1 y porque es la arquitectura que debe escalar.
- **Un resultado incómodo que reportamos tal cual.** El embedding de departamento cumplió la regla numérica, pero no se adoptó por la regla 8: acertaba 0,8 de 9 transiciones (frente a 2,0) y no transfiere a territorios nuevos. En 2026 obtuvo log-loss 0,314 y AUC 0,933, mejor que el modelo adoptado. No cambiamos la decisión, porque

elegir con la prueba la invalidaría. La lectura es que los efectos fijos territoriales tienen valor predictivo que las variables actuales no capturan (R7).

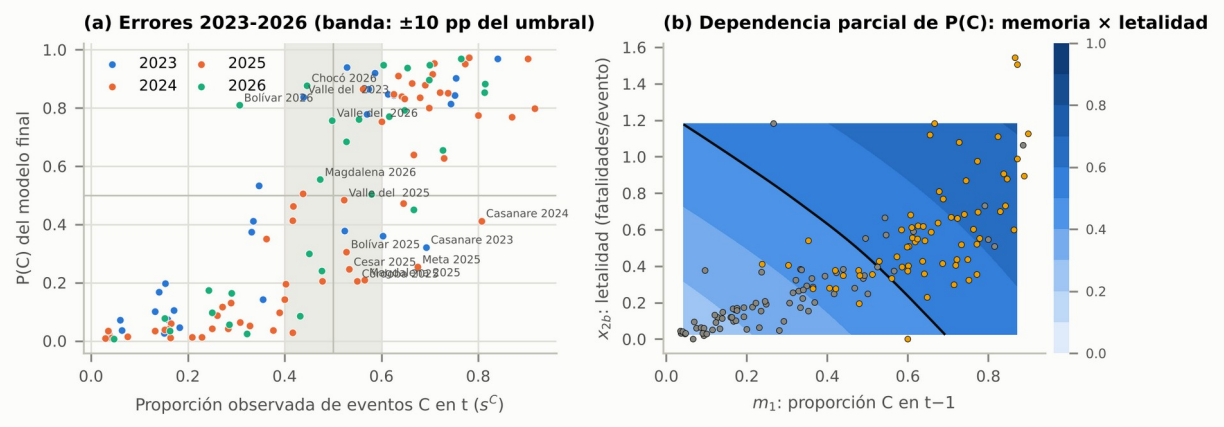


Figura 7: (a) P(C) predicha frente a la proporción observada, 2023-2026 (rótulos: errores en transiciones y Casanare). (b) Dependencia parcial de P(C) entre memoria y letalidad (línea negra: P = 0,5)

7. Integración final del modelo en un pipeline estructurado

El vacío principal frente a la guía era la integración: en la U2 el cuaderno lo hacía todo. En la U3, todo el proceso vive en el paquete `perfil_amenaza` del repositorio, con siete módulos: `config`, `datos`, `variables`, `modelo`, `evaluacion`, `pipeline` y `graficos`. El cuaderno importa ese paquete en lugar de duplicar la lógica. Una sola orden ejecuta las 8 etapas de la Figura 8 en unos 30 segundos, y cada etapa deja un artefacto verificable.

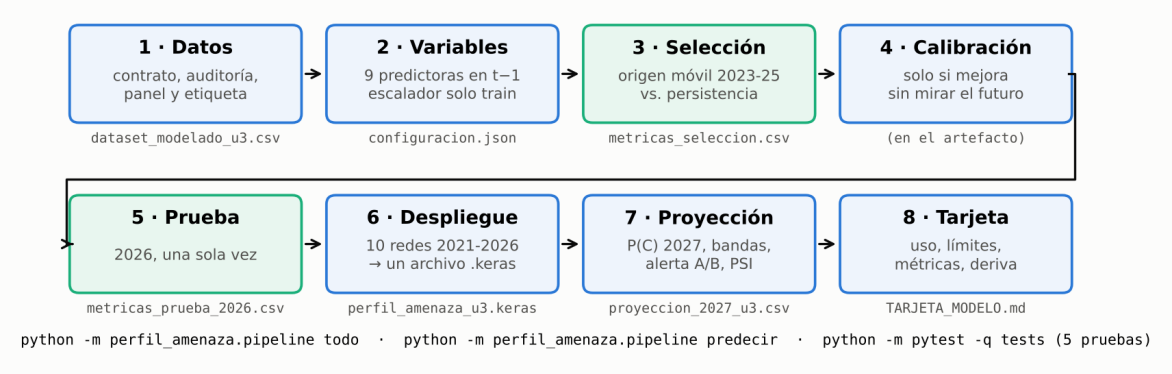


Figura 8: Pipeline integrado. Las decisiones se congelan en configuracion.json antes de la prueba 2026

- **Artefacto único.** Un archivo `perfil_amenaza_u3.keras` (152 KB) contiene la estandarización (capa Normalization con las medias y desviaciones del entrenamiento), las 10 redes, el promedio y la capa de calibración. Recibe las 9 variables en su escala original y devuelve P(C), sin depender del cuaderno.
- **Pruebas automáticas (pytest).** Contrato de datos, ausencia de fuga temporal (multiplicar por 5 los eventos de 2024 no cambia ninguna predictora de las filas de 2024 y sí las de 2025), escalador ajustado solo con años anteriores, determinismo y reproducción del dataset de la U2. Las 5 pasan.
- **Consistencia.** Las log-loss del pipeline (0,304 en selección y 0,380 en prueba) coinciden al cuarto decimal con las del cuaderno. El repositorio incluye `ejecutar_todo.bat`, que reproduce todo en Windows con un solo comando.
- **Operación.** La tarjeta del modelo (Mitchell et al., 2019) fija el uso previsto, los límites y el mantenimiento. El índice de estabilidad poblacional (PSI) de la información de 2026 marca deriva en m_1 (0,29) y en la letalidad (0,25), así que la proyección 2027 debe leerse con más cautela que la de un año estable.

8. Del modelo a la decisión: priorización territorial 2027

El ensamble se reentrenó con todas las etiquetas 2021–2026 y se aplicó, a través del artefacto, a la información de 2026. Clasifica **11 departamentos como C consolidado** ($P \geq 0{,}7$: Guaviare, Nariño, Cauca, Caquetá, Putumayo, Antioquia, Norte de Santander, Vichada y Cesar, además de Amazonas y Vaupés, que tienen pocos datos), **11 en transición** y **11 como D consolidado**.

La traducción a capacidades sigue la Etapa 1: ISR, detección temprana y movilidad protegida donde domina C; portafolio flexible y monitoreo trimestral en transición; orden público y capacidades mixtas en D. **Guaviare (14,4 %) y Cauca (13,4 %)** mantienen la **alerta A/B**, por su proporción de explosivos y drones: allí conviene sumar C-UAS y detección de AEI.

Frente a la U2, 25 de 33 departamentos conservan su categoría. Las discrepancias con el perfil observado en 2026 bajan de 10 a 3 (Chocó, Valle del Cauca y Meta). Chocó y Valle son desescaladas recientes con s^C de 2026 entre 0,45 y 0,50, la franja ambigua. La dispersión entre las 10 redes crece donde el modelo duda (Chocó 0,16; Córdoba 0,12), y debe leerse junto con la probabilidad. Es un insumo para priorizar, no un reemplazo del análisis de inteligencia.

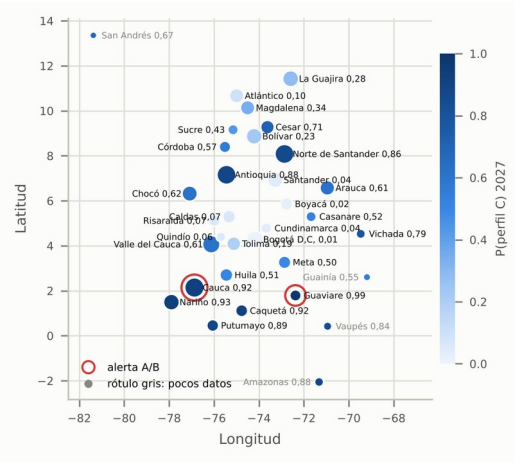


Figura 9: P(perfil C) proyectada para 2027 (centroides; tamaño proporcional a los eventos de 2026)

9. Conclusiones técnicas y recomendaciones futuras

1. **Coherencia.** El modelo final responde la misma pregunta de la U1, con la misma etiqueta, el mismo diseño $t-1 \rightarrow t$ y las mismas variables estructurales, y agrega dos variables que operacionalizan la "intensidad histórica" de la U1 como composición reciente.
2. **Optimizar fue intervenir los datos, no la arquitectura.** De 10 frentes evaluados se retuvieron tres (m_1, d_1 y el ensamble). La capacidad, la profundidad, las redes secuenciales, la salida multitarea, el objetivo blando, la vecindad, los actores y la calibración no superaron el ruido entre semillas. La validación anidada mostró por qué no conviene ajustar hiperparámetros con tan pocos datos.
3. **Impacto real.** La log-loss baja de 0,407 a 0,304 en selección y de 0,524 a 0,380 en la prueba 2026. Frente a la persistencia, el modelo es mejor en calidad probabilística (selección, territorios nuevos y 2026), con intervalos que aún tocan el cero.
4. **Límites.** Anticipa 2 de 13 transiciones. No supera a una logística con las mismas variables. Los efectos fijos territoriales (embedding) contienen información que las variables no explican.

Tabla 7: Recomendaciones priorizadas para la siguiente iteración

#	Recomendación	Evidencia	Acción concreta
R1	Migrar a municipio (M3)	Generalización espacial resuelta (§6)	Acceso académico al registro por evento de ACLED; el pipeline solo cambia `datos.py`
R2	x_3 a escala municipal	El conteo anual por departamento empeoró (I3)	Medir entradas y salidas de grupos por municipio, no el conteo anual
R3	Señales adelantadas de transición	11 de 19 errores son transiciones	Variables mensuales del último trimestre, ceses al fuego y negociaciones
R4	Reentrenar cada año y vigilar el PSI	PSI de m_1 = 0,29; prevalencia 41-62 %	Ejecutar el pipeline al cierre de cada año; decidir con bandas, no con un umbral fijo
R5	Revisar logaritmos y MIN_EVENTOS	Controles de §2.2	Repetir la batería de controles con el dataset municipal
R7	Reevaluar el embedding con 2026 cerrado	Mejor en la prueba 2026 (0,314)	Candidato en la selección 2024-2026; a escala municipal, reemplazarlo por x_3 y distancia

10. Trabajo en equipo y organización

Mantuvimos la división de las etapas anteriores y la llevamos a los cuatro roles que pide la guía. Las decisiones metodológicas se tomaron en conjunto y quedaron en la bitácora del cuaderno (D11–D20, con alternativas y evidencia).

Tabla 8: Roles técnicos de la Unidad 3

Rol	Responsable	Entregables
Modelado	Juan Diego Saldarriaga	Paquete perfil_amenaza, intervenciones I1–I9, rejilla y validación anidada, pipeline y pruebas
Evaluación	Conjunta (cálculo: Juan Diego; interpretación: Laura)	Protocolo y regla de retención, controles, antes vs. después, análisis de errores
Documentación	Laura Díaz Sastoque	Interpretaciones, tarjeta del modelo, informe y README
Presentación	Laura (guion) · Juan Diego (demostración)	Video ejecutivo de 8 a 10 minutos y sustentación

11. Referencias bibliográficas en APA 7

Nota: declaramos el uso de inteligencia artificial (Claude, de Anthropic) como apoyo en la programación del pipeline y del cuaderno. La propuesta del proyecto, la búsqueda de datos, el análisis, las decisiones metodológicas y las conclusiones son del equipo, que ejecutó, revisó y verificó todos los resultados.

Bergmeir, C., & Benítez, J. M. (2012). On the use of cross-validation for time series predictor evaluation. *Information Sciences, 191*, 192–213. https://doi.org/10.1016/j.ins.2011.12.028

Cawley, G. C., & Talbot, N. L. C. (2010). On over-fitting in model selection and subsequent selection bias in performance evaluation. *Journal of Machine Learning Research, 11*, 2079–2107.

Departamento Administrativo Nacional de Estadística (DANE). (2019). *Pobreza multidimensional por departamentos 2018: Resultados*. DANE.

Dietterich, T. G. (1998). Approximate statistical tests for comparing supervised classification learning algorithms. *Neural Computation, 10*(7), 1895–1923. https://doi.org/10.1162/089976698300017197

Géron, A. (2017). *Hands-on machine learning with Scikit-Learn and TensorFlow*. O'Reilly Media.

Gneiting, T., & Raftery, A. E. (2007). Strictly proper scoring rules, prediction, and estimation. *Journal of the American Statistical Association, 102*(477), 359–378. https://doi.org/10.1198/016214506000001437

Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep learning*. MIT Press.

Guo, C., Pleiss, G., Sun, Y., & Weinberger, K. Q. (2017). On calibration of modern neural networks. En *Proceedings of the 34th International Conference on Machine Learning* (pp. 1321–1330).

Hansen, M. C., Potapov, P. V., Moore, R., Hancher, M., Turubanova, S. A., Tyukavina, A., … Townshend, J. R. G. (2013). High-resolution global maps of 21st-century forest cover change. *Science, 342*(6160), 850–853. https://doi.org/10.1126/science.1244693

Kingma, D. P., & Ba, J. (2015). Adam: A method for stochastic optimization. En *International Conference on Learning Representations*. https://arxiv.org/abs/1412.6980

Lakshminarayanan, B., Pritzel, A., & Blundell, C. (2017). Simple and scalable predictive uncertainty estimation using deep ensembles. En *Advances in Neural Information Processing Systems 30*.

Ministerio de Defensa de Colombia. (2025). *Informe de gestión: modernización y transformación de las Fuerzas Militares*. Ministerio de Defensa Nacional.

Ministerio de Justicia y del Derecho – Observatorio de Drogas de Colombia. (2026). *Detección de cultivos de coca (hectáreas)* [Conjunto de datos]. Datos Abiertos Colombia. https://www.datos.gov.co/d/acs4-3wgp

Mitchell, M., Wu, S., Zaldivar, A., Barnes, P., Vasserman, L., Hutchinson, B., … Gebru, T. (2019). Model cards for model reporting. En *Proceedings of the Conference on Fairness, Accountability, and Transparency* (pp. 220–229). https://doi.org/10.1145/3287560.3287596

Platt, J. (1999). Probabilistic outputs for support vector machines and comparisons to regularized likelihood methods. En A. Smola et al. (Eds.), *Advances in large margin classifiers* (pp. 61–74). MIT Press.

Raleigh, C., Linke, A., Hegre, H., & Karlsen, J. (2010). Introducing ACLED: An armed conflict location and event dataset. *Journal of Peace Research, 47*(5), 651–660. https://doi.org/10.1177/0022343310378914

Roberts, D. R., Bahn, V., Ciuti, S., Boyce, M. S., Elith, J., Guillera-Arroita, G., … Dormann, C. F. (2017). Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure. *Ecography, 40*(8), 913–929. https://doi.org/10.1111/ecog.02881

Sundberg, R., & Melander, E. (2013). Introducing the UCDP Georeferenced Event Dataset. *Journal of Peace Research, 50*(4), 523–532. https://doi.org/10.1177/0022343313484347